

1.a

$$\text{posterior} = f(\theta|x) = \frac{f(x|\theta) f(\theta)}{\int_0^{\frac{1}{\sqrt{5}}} f(x|\theta) f(\theta) d\theta} = \frac{\theta e^{-\theta x} (10\theta)}{\int_0^{\frac{1}{\sqrt{5}}} 10\theta^2 e^{-\theta x} d\theta}$$

$$= \frac{10\theta^2 e^{-\theta x}}{\frac{-10(x^2\theta^2 + 2x\theta + 2)e^{-\theta x}}{x^3} \Big|_{\theta=0}^{\theta=\frac{1}{\sqrt{5}}}} = \frac{\theta^2 e^{-\theta x} x^3}{2 - (x^2\frac{1}{5} + 2x\frac{1}{\sqrt{5}} + 2)e^{-\frac{x}{\sqrt{5}}}} \quad \begin{matrix} x \geq 0 \\ 0 \leq \theta \leq \frac{1}{\sqrt{5}} \end{matrix}$$

$$\rightarrow f(\theta|x=30) = \frac{27000\theta^2 e^{-30\theta}}{2 - (180 + 12\sqrt{5} + 2)e^{-6\sqrt{5}}}$$

1.b $\hat{\theta} = \arg\max_{\theta} f(\theta|x=30) = \arg\max_{\theta} \underbrace{\lg 27000}_{\text{const}} + \underbrace{\lg(\theta^2 e^{-30\theta})}_{\text{const}} - \underbrace{\lg(2 - (180 + 12\sqrt{5} + 2)e^{-6\sqrt{5}})}_{\text{const}}$

$$\frac{\partial}{\partial \theta} \rightarrow \frac{2\theta e^{-30\theta} - 30e^{-30\theta}\theta^2}{\theta^2 e^{-30\theta}} = \frac{2 - 30\theta}{\theta} = 0 \rightarrow \theta = \frac{1}{15}$$

همان طور که ملاحظه می شود در MAP منحنی posterior هر نیست زیرا نرم θ ندارد و در مرحله مشتق گیری 0 می شود

2.1 $E[\hat{I}_n(f)] = E\left[\frac{1}{n} \sum_{i=1}^n \frac{f(x_i)}{g(x_i)}\right] = \frac{1}{n} \sum_{i=1}^n E\left[\frac{f(x_i)}{g(x_i)}\right] = \frac{1}{n} \times n \times \int_a^b f(x_i) dx_i = I(f)$

$\int_a^b \frac{f(x_i)}{g(x_i)} g(x_i) dx_i$

2.2 $\lim_{n \rightarrow \infty} P(|\hat{I}_n(f) - I(f)| \geq \varepsilon) = 0 \quad \forall \varepsilon > 0$ $\hat{I}_n(f)$ تخمینگر $I(f)$ است. بنابراین باید نشان دهیم:

طبق law of large numbers برای E می دانیم که اگر z_1, \dots, z_n iid باشند داریم: $\lim_{n \rightarrow \infty} P(|\bar{z}_n - E[z]| \geq \varepsilon) = 0 \quad \forall \varepsilon > 0$

حال اگر قرار دهیم: $z_i = \frac{f(x_i)}{g(x_i)}$ مفاهیم داریم: $E[z] = I(f)$ و $\bar{z}_n = \hat{I}_n(f)$

$$\lim_{n \rightarrow \infty} P(|\hat{I}_n(f) - I(f)| \geq \varepsilon) = 0 \quad \forall \varepsilon > 0$$

بنابراین $\hat{I}_n(f)$ یک تخمینگر consistent است و در تعداد داده بالا به مقدار اصلی نزدیک می شود

$$\boxed{2.3} \quad \text{Var} \left[\frac{1}{n} \sum_{i=1}^n \frac{f(x_i)}{g(x_i)} \right] = \frac{1}{n^2} \sum_{i=1}^n \text{Var} \left[\frac{f(x_i)}{g(x_i)} \right] = \frac{1}{n} \left[E \left[\left(\frac{f(x_i)}{g(x_i)} \right)^2 \right] - I(f)^2 \right]$$

$$= \frac{1}{n} \left[\int_a^b \frac{f(x_i)^2}{g(x_i)} dx_i - I(f)^2 \right]$$

3

ابتدا حالتی را به دست می آوریم که σ^2 را می دانیم: متغیر تصادفی Z را به صورت زیر تعریف می کنیم:

$$Z = \frac{\bar{X} - \theta}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1) \rightarrow P(|Z| \geq b) \leq 1 - 0.95 \rightarrow b = -\Phi^{-1}\left(\frac{1-0.95}{2}\right) = 1.96$$

0.025

$$\rightarrow -1.96 \leq \frac{\bar{X} - \theta}{\frac{\sigma}{\sqrt{n}}} \leq 1.96 \rightarrow \theta \in \left[\bar{X} - 1.96 \frac{\sigma}{\sqrt{n}}, \bar{X} + 1.96 \frac{\sigma}{\sqrt{n}} \right] \xrightarrow[\sigma=5]{\bar{X}=65} [61.9, 68.1]$$

حال برای حالتی که σ^2 را ندانیم حساب می کنیم. متغیر تصادفی Z و Y را به صورت زیر تعریف می کنیم:

$$Z = \frac{\bar{X} - \theta}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

$$Y = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \text{ chi-squared}$$

$$\left. \begin{array}{l} Z \\ Y \end{array} \right\} \rightarrow \text{طبق تعریف توزیع } t\text{-distribution می دانیم}$$

$$\frac{\mathcal{N}(0,1)}{\sqrt{\frac{\chi^2(n)}{n}}} = T(n)$$

$$\rightarrow T = \frac{Z}{\sqrt{\frac{Y}{n-1}}} = \frac{\bar{X} - \theta}{\frac{S}{\sqrt{n}}} \sim T(n-1)$$

اگر CDF^{-1} - توزیع $T(n-1)$ را t_{n-1} بنامیم می توانیم بنویسیم:

$$\theta \in \left[\bar{X} - t_{n-1} \left(\frac{1-0.95}{2} \right) \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1} \left(\frac{1-0.95}{2} \right) \frac{S}{\sqrt{n}} \right]$$

$$\left. \begin{array}{l} \bar{X} = 65 \\ S = 5.98 \\ t_9(0.025) = 2.262 \end{array} \right\} \rightarrow \theta \in [60.72, 69.28]$$

⊗ همان طور که مشاهده می شود اگر واریانس را بدانیم بازه tightتری برای θ به دست می آوریم که منطقی هم هست زیرا اطلاعات بیشتری داریم.

⊗ به طور کلی وقتی واریانس را ندانیم روش های مختلفی وجود دارد مثلاً می توان برای σ یک تخمینگر بازه ای به دست آورد و با حد بالایی آن به بازه ای برای θ رسید اما کاری که در اینجا کردیم جواب دقیق تری است.

4.a

$f(Y|X=n_i) \sim \mathcal{N}(\beta_0 + \beta_1 x_i, \sigma^2)$: با توجه به اینکه β_0 و β_1 پارامترهای ثابت هستند و x_i متغیر تصادفی است.

$$\begin{aligned} \hat{\beta}_0, \hat{\beta}_1 &= \arg \max_{\beta_0, \beta_1} \prod_{i=1}^n f(Y=y_i | X=x_i) \\ &= \arg \max_{\beta_0, \beta_1} \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - (\beta_0 + \beta_1 x_i))^2}{2\sigma^2}\right) \\ &= \arg \max_{\beta_0, \beta_1} \sum_{i=1}^n -\frac{(y_i - (\beta_0 + \beta_1 x_i))^2}{2\sigma^2} = \arg \min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2 \rightarrow \text{MSE} \end{aligned}$$

4.b

$$\frac{\partial \text{MSE}}{\partial \beta_0} = \sum_{i=1}^n -2(y_i - \beta_0 - \beta_1 x_i) = 0 \rightarrow \hat{\beta}_0 = \frac{\sum (y_i - \hat{\beta}_1 x_i)}{n} = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\frac{\partial \text{MSE}}{\partial \beta_1} = \sum_{i=1}^n -2(y_i - \beta_0 - \beta_1 x_i) x_i = 0 \rightarrow \sum x_i y_i - \beta_0 \sum x_i - \beta_1 \sum x_i^2 = 0$$

$$\rightarrow \sum x_i y_i - \bar{y} \sum x_i + \underbrace{\hat{\beta}_1 \bar{x} \sum x_i - \hat{\beta}_1 \sum x_i^2}_{\hat{\beta}_1 (n\bar{x}^2 - \sum x_i^2)} = 0$$

$$\rightarrow \hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{y}\bar{x}}{\sum x_i^2 - n\bar{x}^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

هر دو β_0 و β_1 از ترکیب خطی و ضرب کاهشی ما به دست آمده اند و کاهشی هستند.

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(\beta_1(x_i - \bar{x}) + \varepsilon_i - \bar{\varepsilon})}{\sum (x_i - \bar{x})^2} = \beta_1 + \frac{\sum (x_i - \bar{x})\varepsilon_i}{\sum (x_i - \bar{x})^2} - \underbrace{\frac{\bar{\varepsilon} \sum (x_i - \bar{x})}{\sum (x_i - \bar{x})^2}}_0$$

$$E[\hat{\beta}_1] = \beta_1 + 0 = \beta_1 \rightarrow \text{unbiased} \checkmark$$

$$\text{Var}[\hat{\beta}_1] = 0 + \frac{1}{(\sum (x_i - \bar{x})^2)^2} \underbrace{\text{Var}[\sum (x_i - \bar{x})\varepsilon_i]}_{\sum (x_i - \bar{x})^2 \sigma^2} = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$$

$$\rightarrow \hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right)$$

4.b

نویس

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \beta_0 + \beta_1 \bar{x} + \bar{\varepsilon} - \hat{\beta}_1 \bar{x} = \beta_0 - \frac{\sum (x_i - \bar{x}) \varepsilon_i}{\sum (x_i - \bar{x})^2} \bar{x} + \bar{\varepsilon}$$

$$E[\hat{\beta}_0] = \beta_0 + 0 + 0 = \beta_0 \rightarrow \text{unbiased} \checkmark$$

$$\text{Var}[\hat{\beta}_0] = \frac{\bar{x}^2 \sigma^2}{\sum (x_i - \bar{x})^2} + \frac{\sigma^2}{n} = \frac{\sum x_i^2 - n \bar{x}^2 + n \bar{x}^2}{n \sum (x_i - \bar{x})^2} \sigma^2 = \frac{\sigma^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}$$

$$\rightarrow \hat{\beta}_0 \sim \mathcal{N}\left(\beta_0, \frac{\sigma^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}\right)$$

4.c

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2} - \frac{\bar{y} \sum (x_i - \bar{x})}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x}) y_i - \bar{y} \sum (x_i - \bar{x})} \\ &= \frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x}) y_i} \end{aligned}$$

باین این عبارت ساده است

$$\checkmark \frac{\sum y_i y_i}{\sum y_i x_i} \leftarrow y_i = x_i - \bar{x} \text{ باین این عبارت ساده است}$$

$$\checkmark \sum y_i = \sum (x_i - \bar{x}) = 0$$

4.d

$$\tilde{\beta}_1 = \frac{\sum y_i y_i}{\sum y_i x_i} = \frac{\sum y_i (\beta_0 + \beta_1 x_i + \varepsilon_i)}{\sum y_i x_i} = \frac{\beta_0 \sum y_i + \beta_1 \sum y_i x_i + \sum y_i \varepsilon_i}{\sum y_i x_i} = \beta_1 + \frac{\sum y_i \varepsilon_i}{\sum y_i x_i}$$

$$\rightarrow E[\tilde{\beta}_1] = \beta_1 + 0 = \beta_1 \rightarrow \text{unbiased}$$

4.e

4.d \rightarrow $\text{Var}[\tilde{\beta}_i] = \frac{\epsilon^2 \sum \gamma_i^2}{(\sum \gamma_i x_i)^2}$

4.b \rightarrow $\text{Var}[\hat{\beta}_i] = \frac{\epsilon^2}{\sum (x_i - \bar{x})^2}$

$$\begin{aligned} \sum \gamma_i (x_i - \bar{x}) &= \sum \gamma_i x_i - \bar{x} \sum \gamma_i \\ &= \sum \gamma_i x_i - \bar{x} \cdot 0 \\ &= \sum \gamma_i x_i \end{aligned}$$

برای مقایسه این دو واریانس از نامساوی کوچی استفاده می‌کنیم. به طور کلی داریم:

$$\left(\sum \gamma_i (x_i - \bar{x}) \right)^2 \leq \left(\sum \gamma_i^2 \right) \left(\sum (x_i - \bar{x})^2 \right)$$

$$\left(\sum \gamma_i x_i \right)^2 \quad (*)$$

$$\rightarrow \frac{\sum \gamma_i^2}{(\sum \gamma_i x_i)^2} \geq \frac{1}{\sum (x_i - \bar{x})^2} \xrightarrow{\times \epsilon^2} \text{Var}[\tilde{\beta}_i] \geq \text{Var}[\hat{\beta}_i]$$

$$\boxed{5} \quad \hat{\lambda} = \arg \max_{\lambda} \underbrace{f_{\lambda}(\lambda)}_{\beta^{\alpha} \lambda^{\alpha-1} e^{-\beta \lambda}} \underbrace{\prod_{i=1}^n f(x_i | \lambda)}_{\lambda e^{-\lambda x_i}} = \arg \max_{\lambda} \alpha \lg \beta + (\alpha-1) \lg \lambda - \beta \lambda + \sum_{i=1}^n \lg \lambda - \lambda x_i$$

$$\frac{\partial}{\partial \lambda} \rightarrow \frac{\alpha-1}{\lambda} - \beta + \sum_{i=1}^n \frac{1}{\lambda} - x_i = 0 \rightarrow \frac{\alpha+n-1}{\lambda} = \beta + \sum_{i=1}^n x_i$$

$$\rightarrow \hat{\lambda} = \frac{\alpha+n-1}{\beta + \sum_{i=1}^n x_i}$$

$$\boxed{6} \quad \hat{X} = \arg \max_x f(X|Y=3) = \arg \max_x p(Y=3|x) f(x)$$

$$= \arg \max_x (1-x)^2 x (3x^2) \quad 0 \leq x \leq 1$$

آن فرم از توزیع geo را در نظر گرفتیم که سایرین شامل صفر نیست

$$\frac{\partial}{\partial x} \rightarrow 9x^2(1-x)^2 - 6(1-x)x^3 = 0 \rightarrow x = 0, \frac{3}{5}, 1$$

نقطه $\frac{3}{5}$ را بررسی می‌کنیم

$$\rightarrow \hat{X} = \frac{3}{5}$$

$$\boxed{7} \quad f(Y|x; a) = f(aX + \varepsilon | X; a) \rightarrow \text{Zaslavsky}$$

$$E[Y|X; a] = aX, \quad \text{Var}[Y|X; a] = \sigma^2$$

$$\hat{a} = \arg \max_a \prod_{i=1}^n \underbrace{f(Y_i | X_i; a)}_{\frac{1}{\sqrt{2\pi}\sigma} \exp(-\frac{(Y_i - aX_i)^2}{2\sigma^2})} = \arg \max_a \sum_{i=1}^n \underbrace{-\lg(\sqrt{2\pi}\sigma)}_{\text{const}} - \frac{(Y_i - aX_i)^2}{2\sigma^2}$$

$$\frac{\partial}{\partial a} \rightarrow \sum_{i=1}^n \frac{-1}{2\sigma^2} 2(Y_i - aX_i)(-X_i) = 0 \rightarrow \frac{1}{\sigma^2} \sum_{i=1}^n Y_i X_i - a \sum_{i=1}^n X_i^2 = 0$$

$$\rightarrow \sum_{i=1}^n Y_i X_i = a \sum_{i=1}^n X_i^2 \rightarrow a = \frac{\sum Y_i X_i}{\sum X_i^2}$$

- source 1