

$$\boxed{1.1} \quad X = \begin{matrix} & x^{(1)} & x^{(2)} & x^{(3)} \\ \begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix} \end{matrix} \rightarrow XX^T = \begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 0 \\ -1 & -1 \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$$

Finding eigen vectors of $XX^T \rightarrow \begin{vmatrix} 2-\lambda & 2 \\ 2 & 2-\lambda \end{vmatrix} = (2-\lambda)^2 - 4 = 0 \rightarrow \begin{cases} 2-\lambda = 2 \rightarrow \lambda = 0 \\ 2-\lambda = -2 \rightarrow \lambda = 4 \end{cases}$

$$\xrightarrow{\lambda=0} \begin{bmatrix} 2 & 2 & | & 0 \\ 2 & 2 & | & 0 \end{bmatrix} \equiv \begin{bmatrix} 1 & 1 & | & 0 \\ 0 & 0 & | & 0 \end{bmatrix} \rightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -x_2 \\ x_2 \end{bmatrix} \rightarrow \text{eigen vec} = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \xrightarrow{\text{normalize}} \begin{bmatrix} \frac{-\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = p_{c_1}$$

$$\lambda = 4 \rightarrow \left[\begin{array}{cc|c} -2 & 2 & 0 \\ 2 & -2 & 0 \end{array} \right] \equiv \left[\begin{array}{cc|c} 1 & -1 & 0 \\ 0 & 0 & 0 \end{array} \right] \rightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_2 \\ x_2 \end{bmatrix} \rightarrow \text{eigen vec} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \xrightarrow{\text{normalize}} \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = p_{c_2}$$

دو بردار p_{c_1}, p_{c_2} مولفه های اصلی هستند

1.2

$$\text{proj}_u(v) = \frac{\langle u, v \rangle}{\langle u, u \rangle} u$$

$$\left. \begin{aligned} \text{proj}_{P_{C_1}}(x^{(1)}) &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \text{proj}_{P_{C_1}}(x^{(2)}) &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \text{proj}_{P_{C_1}}(x^{(3)}) &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \end{aligned} \right\} \rightarrow \text{var} = \frac{1}{3} (0^2 + 0^2 + 0^2) = \boxed{0}$$

اگر تنها PC_1 وجود داشته باشد، باید داریم:

$$\left. \begin{aligned} \text{proj}_{P_{C_2}}(x^{(1)}) &= \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ \text{proj}_{P_{C_2}}(x^{(2)}) &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \text{proj}_{P_{C_2}}(x^{(3)}) &= \begin{bmatrix} -1 \\ -1 \end{bmatrix} \end{aligned} \right\} \rightarrow \text{var} = \frac{1}{3} (\sqrt{2}^2 + 0^2 + \sqrt{2}^2) = \boxed{\frac{4}{3}}$$

به صورت مناسب برای PC_2 داریم :

1.3

$$\text{میانگین خطای بازسازی} = \frac{1}{n} \sum_{i=1}^n \|x^{(i)} - \text{proj}(x^{(i)})\|^2$$

$$p_{c1} \frac{1}{3} \left[\|x^{(1)}\|^2 + \|x^{(2)}\|^2 + \|x^{(3)}\|^2 \right] = \frac{1}{3} (2 + 0 + 2) = \frac{4}{3}$$

$$p_{c2} \frac{1}{3} \left[\left\| \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\|^2 + \left\| \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\|^2 + \left\| \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\|^2 \right] = 0$$

2.1

$$p(F | A, S, H, N) = p(F)$$

$$p(A | F, S, H, N) = p(A)$$

$$p(S | A, F, H, N) = p(S | A, F)$$

$$p(H | A, F, S, N) = p(H | S)$$

$$p(N | A, F, S, H) = p(N | S)$$

می‌دانیم که با داشتن شبکه می‌توان احتمال سرگی هر فرد به سرگ پدرانش، از سایر نودها مستقل است. پس داریم:

2.2

$$p(A=1 | F, S, H, N) = \frac{p(A=1, F, S, H, N)}{p(F, S, H, N)}$$

$$= \frac{p(A=1) p(F) p(S | A=1, F) p(N | S) p(H | S)}{\sum_{i=0}^1 p(A=i) p(F) p(S | A=i, F) p(N | S) p(H | S)} = \frac{p(A=1) p(S | A=1, F)}{\sum_{i=0}^1 p(A=i) p(S | A=i, F)}$$

markov blanket

2.3

پسوند مارکو هر نود شامل فرزندانش مستقیم، پدرانش مستقیم و نودهایی است که با آنها فرزند مشترک داریم. $\text{markov blanket}(A) = \{S, F\}$

2.4

همان‌طور که در قسمت ج نشان دادیم، متغیرهایی که عضو پسوند مارکو نباشند، در مرحله آخر خط می‌خورند و عبارت نهایی آنها شامل اعضای پسوند مارکو است.

2.5

تنها متغیری که ثابت نیست و در مرحله ایدرافنی می‌تواند تغییر کند A است پس تمامی توزیع‌هایی که A در آن‌ها حضور دارد نیز باید دوباره بررسی شوند. پس جواب توزیع‌های زیر است:

$$p(S=0 | A=0, F=0) \quad p(A=0)$$

$$p(S=0 | A=0, F=1) \quad p(A=1)$$

$$p(S=0 | A=1, F=0)$$

$$p(S=0 | A=1, F=1)$$

$$p(S=1 | A=0, F=0)$$

$$p(S=1 | A=0, F=1)$$

$$p(S=1 | A=1, F=0)$$

$$p(S=1 | A=1, F=1)$$

2.6

سدن آخر در حقیقت توزیع $p(A=1)$ را اعلام می‌کند که در مرحله امید ریاضی قبلی به دست آمده است. باقی سدن ها نیز ثابت اند. بنابراین می‌توان فرایند های سوال را طبق جدول و به صورت empirical گزارش کرد:

طبق ردیف های 1, 2, 4, 5
می‌توان گفت

$$p(A=1) = \frac{1 + 1 + 0.8 + 0.4}{5} = 0.64$$

$$p(s=1 | F=0, A=1) = \frac{p(s=1, F=0, A=1)}{p(F=0, A=1)} = \frac{\frac{1+0.4}{5}}{\frac{1+1+0.8+0.4}{5}} = \frac{0.28}{0.64} = 0.4375$$

3.1

همان طور که در درس دیدیم، در ابعاد بالا با مفهومی تحت عنوان curse of dimensionality روبرو می‌شویم که سمدن ما از distance را فریب می‌دهد. از جمله معضلات های آن می‌توان به موارد زیر اشاره کرد:

- neighborhoods are no longer local
- points in high dimensional spaces are isolated
- the notion of nearest neighbors vanishes
- ...


به این معنا که در ابعاد بالا تمام فواصل با هم یکسان می‌شوند و الگوریتمی مثل k-means دیگر نمی‌تواند به صورت مفادار و بهینه خوشه بندی را انجام دهد زیرا تمام نقاط فاصله های مشابهی خواهند داشت

3.2

در رابطه با تأثیر normalization معمولاً به دو مورد زیر اشاره می‌شود

1. اگر ویژگی ها normalize نشده باشند، در محاسبه distance، ویژگی هایی که scale بزرگتری دارند سایر ویژگی ها را dominate می‌کنند. این در حالی است که ممکن است آن ویژگی ها واقعاً آلوده مهم نباشند. با normalize کردن تأثیر هر ویژگی برابر distance می‌گردد و این اتفاق نیفتد

2. اگر ویژگی ها normalize نشده باشند، converge کردن الگوریتم ها نیز می‌تواند کند تر شود. به خصوص الگوریتم هایی که از gradient descent استفاده می‌کنند، اگر scale پارامترهای مدل متفاوت باشد، برداشتن gradient step با اندازه یکسان در این فضا سبب ایجاد oscillation می‌شود



3.3

آن طور که از مشاهده داده ها به نظر می رسد، خوشه بندی درست به این صورت است که هر کدام از خم های نعلی شکل باید یک خوشه باشند. اما چدن k-means بر اساس فاصله میله ها خوشه بندی می کند نمی تواند این شکل را capture کند خوشه بندی هایی به centroid مایی که در ابتدا انتخاب می شوند نیز وابسته است اما واضح است که مدل تیرمچ می دهد مثلاً a, b را در یک خوشه بگیرد تا a, c

