

با توجه به fair بودن تاس برای وظیفه 1 احتمال رخداد هر عدد $\frac{1}{6}$ است

1.a

برای وظیفه 2 ابتدا تاس اول پرتاب شده و سپس هر عددی که آمد باید تاس دوم نیز همان عدد بیاید. یعنی

پرتاب اول اهمیتی در میزان سختی ندارد و پرتاب دوم با یک عدد ثابت باید برابر شود. پس احتمال این حالت نیز $\frac{1}{6}$ است

به عبارت دیگر توسط
احتمال کل داریم $\rightarrow P(X_1 = X_2) = \sum_{i=1}^6 \underbrace{P(X_1 = X_2 | X_1 = i)}_{P(X_2 = i)} P(X_1 = i) = 6 \times \frac{1}{6} \times \frac{1}{6} = \frac{1}{6}$

1.b

$$\sum_{i=1}^n (\alpha_i - \frac{1}{n})^2 = \sum_{i=1}^n (\alpha_i^2 - \frac{2\alpha_i}{n} + \frac{1}{n^2}) = \sum_{i=1}^n \alpha_i^2 - \underbrace{\frac{2}{n} \sum_{i=1}^n \alpha_i}_{-\frac{1}{n}} + \frac{1}{n}$$

$$\rightarrow 0 \leq \sum_{i=1}^n (\alpha_i - \frac{1}{n})^2 = \sum_{i=1}^n \alpha_i^2 - \frac{1}{n} \rightarrow \sum_{i=1}^n \alpha_i^2 \geq \frac{1}{n} \quad (*)$$

1.c

$$P(X_1 = X_2) \stackrel{\text{احتمال کل}}{=} \sum_{i=1}^n \underbrace{P(X_2 = i)}_{\alpha_i} \underbrace{P(X_1 = i)}_{\alpha_i} = \sum_{i=1}^n \alpha_i^2 \stackrel{(*)}{\geq} \frac{1}{n}$$

به ازای توزیع categorical با α_i های برابر $\rightarrow \dots \uparrow \frac{1}{n} \uparrow \dots$ این نابرابری به حداقل مقدار خود یعنی $\frac{1}{n}$ می‌رسد

2.a

$$\mathbb{E}[U] = \frac{1}{\binom{n}{2}} \sum_{j < k} \mathbb{E}[g(x_j, x_k)] \stackrel{x_i \text{ are iid}}{=} \frac{1}{\binom{n}{2}} \sum_{j < k} \mathbb{E}[g(x_1, x_2)]$$

$$= \frac{1}{\binom{n}{2}} \times \binom{n}{2} \mathbb{E}[g(x_1, x_2)]$$

$$\rightarrow \text{bias}(U) = \mathbb{E}[U] - \mathbb{E}[g(x_1, x_2)] = 0 \rightarrow \text{unbiased}$$

2.b

متغیر تصادفی $Y_{j,k} \triangleq g(x_j, x_k)$ را تعریف می‌کنیم، چون x_i ها iid هستند پس $Y_{j,k}$ ها نیز iid هستند و $0 < Y_{j,k} \leq b$ و $Y_{j,k}$ ها برای آن ها Hoeffding نوشته می‌شود:

$$\mathbb{P}\left(\left|\frac{1}{\binom{n}{2}} \sum_{j < k} Y_{j,k} - \mathbb{E}[Y_{j,k}]\right| \geq t\right) \leq 2e^{\underbrace{\frac{-2\binom{n}{2}t^2}{b^2}}_{\leq e^{\frac{-nt^2}{2b^2}}}}$$

3

در گراف G احتمال وجود یا عدم وجود هر یال را با متغیرهای تصادفی X_1, \dots, X_n iid $\text{Bern}(p)$ می‌کنیم و واضح است که $c(G)$ تابعی از X_i ها است.

تغییر هر X_i حداکثر یک واحد می‌تواند $c(G)$ را تغییر دهد \leftarrow bounded difference property with $c_i = 1$

$$\text{Mc Diarmid} \rightarrow \mathbb{P}(|c(G) - \mathbb{E}[c(G)]| \geq \varepsilon) \leq 2e^{\frac{-2\varepsilon^2}{\sum c_i^2}} = 2e^{\frac{-2\varepsilon^2}{n}}$$

$$\xrightarrow{\varepsilon = n\delta} \mathbb{P}\left(\frac{1}{n} |c(G) - \mathbb{E}[c(G)]| \geq \delta\right) \leq 2e^{-2n\delta^2}$$

4

⊗ هر $f \in \mathcal{F}_S$ به این صورت عمل می کند که یک X_i می گیرد و اگر آن ورودی در مجموعه S وجود داشته

1 فردی می دهد و در غیر این صورت 0.

بنابراین اندازه فضای فضا $|\mathcal{F}_S|$ بی نهایت است.

طبق تعریف uniform convergence برای حالت infinite داریم:

$$X_1, \dots, X_n \stackrel{i.i.d.}{\sim} p \quad \forall f_S \in \mathcal{F}_S$$

$$\forall \delta, \epsilon > 0, \exists n_0 = n_0(\delta, \epsilon) \text{ such that } \forall n \geq n_0$$

$$\mathbb{P}\left(\left|\mathbb{E}_p[f_S(x)] - \frac{1}{n} \sum_{i=1}^n f_S(x_i)\right| \leq \epsilon\right) \geq 1 - \delta$$

یعنی به ازای δ, ϵ فیکس شده باید n_0 ای پیدا شود که از آن جا به بعد کران را داشته باشیم

و p تکلیفی ندارد

حال با توجه به اینکه اعضای S محدود است $\mathbb{E}_p[f_S(x)] = 0$ زیرا مقدار f_S به ازای ص حالت 0 می شود

همینا می توان X_1, \dots, X_n و مجموعه S را جوری انتخاب کرد که تمام X_i ها در S موجود باشند $\leftarrow \frac{1}{n} \sum_{i=1}^n f_S(x_i) = 1$

$$\rightarrow \mathbb{P}(1 \leq \epsilon) \geq 1 - \delta$$


بنابراین مشاهده می شود که به ازای هر ϵ ای باید δ را ندریم. مثلاً

برای $\epsilon = 0.1$ به تناقض می رسیم

پس خانواده توابع \mathcal{F}_S و توزیع p همگامی یکنواخت ندارد

5

الگوریتم پیشنهادی برای تعیین h^* ————— کوچکترین دایره به مرکز مبدأ مختصات که نمونه های $trainset$ را دربر بگیرد



* طبق صورت سوال حالت PAC است و $R(h^*) = 0$

از h^* به اندازه ای به سمت داخل می آیم که احتمال آن بازه برابر ϵ شود
 حال اگر تحلی h^* بیشتر از ϵ باشد به این معناست که هیچ نمونه ای داخل بازه تحلی نخواهد بود (زیرا اگر باشد با فرض الگوریتم پیشنهادی مبنی بر در بر گرفتن تمام نمونه های $trainset$ به تناقض می خوریم)

$$\underbrace{\mathbb{P}(R(\hat{h}^*) \geq \epsilon)}_{\substack{\text{احتمال اینکه تحلی } \hat{h}^* \text{ بیشتر از} \\ \epsilon \text{ باشد}}} = \mathbb{P}\left(\begin{array}{c} \text{هیچ داده ای داخل بازه ی} \\ \text{تحلی نباشد} \end{array}\right) \leq \mathbb{P}\left(\begin{array}{c} \text{هیچ داده ای داخل} \\ \text{بازه هاسدز خورده نباشد} \end{array}\right) = (1-\delta)^n \leq e^{-n\delta} \leq \delta$$

$$\rightarrow n \geq \frac{-\lg \delta}{\epsilon} \rightarrow n \geq \frac{1}{\epsilon} \lg \frac{1}{\delta}$$

بنابراین به تعریف PAC رسیدیم و $n \geq \text{poly}(\frac{1}{\delta}, \frac{1}{\epsilon})$

پس این کلاس از مسائل PAC Learnable هستند

* برای تحلی h^* از h^* به سمت بیرون دایره را در نظر نگرفتیم زیرا این حالت با فرض الگوریتم پیشنهادی مبنی بر کوچکترین دایره ای که تمام نمونه های $trainset$ را در بر می گیرد تناقض خواهد داشت و رخ نمی دهد

6.a

$$\mathbb{E}[\hat{F}_n(t)] = \frac{1}{n} \sum_{i=1}^n \overbrace{\mathbb{E}[\mathbb{1}(X_i \leq t)]}^{F(t)} = F(t)$$

$$\text{Var}[\hat{F}_n(t)] \stackrel{\text{iid}}{=} \frac{1}{n^2} \sum_{i=1}^n \underbrace{\text{Var}[\mathbb{1}(X_i \leq t)]}_{\mathbb{E}[\mathbb{1}(X_i \leq t)^2] - \mathbb{E}[\mathbb{1}(X_i \leq t)]^2} = \frac{F(t) - F(t)^2}{n}$$

بنابراین مشاهده می شود که تخمینگر $\hat{F}_n(t)$ بایاس صفر دارد و $\lim_{n \rightarrow \infty} \text{Var}[\hat{F}_n(t)] = 0$.
 طبق قضیه ای که از درس آمار دانستیم: بایاس و واریانس به سمت صفر میل کنند \longleftrightarrow consistent \checkmark

$$\lim_{n \rightarrow \infty} \hat{F}_n(t) \stackrel{\text{a.s.}}{=} F(t) \quad \text{بنابراین}$$

حال اما با Borel-cantelli نیز اثبات می کنیم:

دنباله event های A_n را به صورت روبه رو تعریف می کنیم: $A_n \triangleq \{|\hat{F}_n(t) - F(t)| \geq \varepsilon\}$

چون $\hat{F}_n(t)$ میانگین تجربی n تا R.V. bernoulli است می توان هاندلینگ نوشت:


$$\mathbb{P}(|\hat{F}_n(t) - \overbrace{\mathbb{E}[\hat{F}_n(t)]}^{F(t)}| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$$

$$\rightarrow \sum_{n=1}^{\infty} \mathbb{P}(A_n) \leq \sum_{n=1}^{\infty} 2e^{-2n\varepsilon^2} < \infty \rightarrow \text{Borel-cantelli} \text{ می توان از} \quad \text{استفاده کرد}$$

$\rightarrow \mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 0 \rightarrow$ مجموعه outcome هایی که ∞ بار تکرار شده اند با احتمال صفر رخ می دهد \rightarrow یعنی n هایی که به ازای آن تفاوت \hat{F}_n و F زیاد است، ∞ بار رخ نمی دهد

$$\rightarrow \mathbb{P}(\lim_{n \rightarrow \infty} |\hat{F}_n(t) - F(t)| = 0) = 1 \quad \equiv \quad \lim_{n \rightarrow \infty} \hat{F}_n(t) \stackrel{\text{a.s.}}{=} F(t)$$

6.6



⊗ x_i ها به طوری انتخاب می‌شوند که سری محدود باشد
uniform

$$F(x_{j-1}) \leq F(x) \leq F(x_j)$$

$\forall x \in \mathbb{R}$

def. $j \in \{1, \dots, m\}$ such that $x \in [x_{j-1}, x_j)$ $m \in \mathbb{N}$

$$\begin{cases} \hat{F}_n(x) - F(x) \leq \hat{F}_n(x_j) - F(x_{j-1}) = \hat{F}_n(x_j) - F(x_j) + \frac{1}{m} \\ \hat{F}_n(x) - F(x) \geq \hat{F}_n(x_{j-1}) - F(x_j) = \hat{F}_n(x_{j-1}) - F(x_{j-1}) - \frac{1}{m} \end{cases}$$

$$\rightarrow \left| \hat{F}_n(x) - F(x) \right| \leq \max_{j=1 \dots m} \left| \hat{F}_n(x_j) - F(x_j) \right| + \frac{1}{m}$$

$$\rightarrow \sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F(x) \right| \leq \max_{j=1 \dots m} \left| \hat{F}_n(x_j) - F(x_j) \right| + \frac{1}{m}$$

deterministic

⊗ m دومین "مثلاً" n یک $\frac{1}{m}$ و $\frac{1}{m}$ بر اساس
تعداد n ها می‌باشد

⊗ این جا چون بازه بندی x_i ها دایمی به n وابسته جاسون رو عوض کرد
پس رسیدن به $\sup_{x \in \mathbb{R}} R(\hat{h}^*)$ نیست که داستان دار باشد

$\forall \varepsilon > 0$ choose $m \in \mathbb{N}$ such that $\frac{1}{m} < \varepsilon$

$$\forall j \quad \mathbb{P}\left(|\hat{F} - F| > \sqrt{\frac{\log \frac{2}{\delta}}{2n}}\right) < \delta$$

union bound $\rightarrow \mathbb{P}\left(\max_{j=1 \dots m} |\hat{F}_n(x_j) - F(x_j)| > \sqrt{\frac{\log \frac{2}{\delta}}{2n}}\right) < m\delta$

rename
 $\delta \rightarrow \frac{\delta}{m}$


$$\sup_x |\hat{F}_n(x) - F(x)| \overset{1-\delta}{\leq} \frac{1}{m} + \sqrt{\frac{\log \frac{2m}{\delta}}{2n}}$$

for n $\gg \frac{1}{\varepsilon^2} \log \frac{1}{\varepsilon}$, m $\gg \frac{1}{\varepsilon}$

$$\rightarrow o\left(\frac{1}{\sqrt{n}}\right) + o\left(\sqrt{\frac{\log \frac{n}{\delta}}{n}}\right) = o\left(\sqrt{\frac{\log \frac{n}{\delta}}{n}}\right)$$

الگوریتم پیشنهادی: ابتدا سیل ها را بر اساس مقادیرشان سورت می کنیم و سپس از ابتدا یک دور تمام مقادیر را traverse می کنیم و هر جا سیل + داریم مقدار آن را به عنوان شروع بازه در نظر گرفته و تا زمانی که سیل های + پشت سرهم مشاهده می کنیم ادامه می دهیم. هر جا این توالی قطع شد مقدار آخرین سیل + را به عنوان پایان بازه ثبت می کنیم (به این صورت p بازه tight به دست می آید)

اجماع این بازه ها جزوی الگوریتم ماست



برای به دست آوردن sample complexity ابتدا حالت $p=2$ را در نظر می گیریم.

تخلی \hat{h}^* نسبت به h^* به سه حالت می تواند باشد

$R1 \leftarrow$ ریسک حالتی که \hat{h}^* بازه کوچکی داخل $[a, b]$ را انتخاب کرده باشد

$R2 \leftarrow$ " " " " " " " " داخل $[c, d]$

$R3 \leftarrow$ ریسک حالتی که به دلیل نریدن سیل training تمام بازه $[b, c]$ نیز جزو بازه \hat{h}^* باشد

چون هر کدام از این حالات به صورت مستقل می تواند رخ دهد

$$P(R(\hat{h}^*) \geq \epsilon) \leq P(R1 \geq \frac{\epsilon}{3} \cup R2 \geq \frac{\epsilon}{3} \cup R3 \geq \frac{\epsilon}{3})$$

$$\begin{aligned} &\stackrel{\text{union bound}}{\leq} 2P(R1 \geq \frac{\epsilon}{3}) + P(R3 \geq \frac{\epsilon}{3}) \\ &\leq P(\text{تخلی } \hat{h}^* \text{ از سمت چپ بیشتر از } \frac{\epsilon}{6} \text{ باشد} \cup \text{تخلی } \hat{h}^* \text{ از سمت راست بیشتر از } \frac{\epsilon}{6} \text{ باشد}) \leq P(\text{هیچ نمونه ای در بازه به هم } \frac{\epsilon}{3} \text{ تکرار نکند}) \\ &\stackrel{\text{union bound}}{\leq} 2P(\text{هیچ نمونه ای در بازه به هم } \frac{\epsilon}{6} \text{ تکرار نکند}) \leq \frac{(1 - \frac{\epsilon}{6})^m}{\leq e^{-\frac{m\epsilon}{6}}} \end{aligned}$$

sample complexity

$$m \geq \frac{6}{\epsilon} \lg \frac{5}{\delta}$$

$$\rightarrow P(R(\hat{h}^*) \geq \epsilon) \leq 4e^{-\frac{m\epsilon}{6}} + e^{-\frac{m\epsilon}{3}} \leq 5e^{-\frac{m\epsilon}{6}} \leq \delta$$

⊕ اگر دو بازه $[a, b]$ و $[c, d]$ disjoint نبوده باشند

$$P(R(\hat{h}^*) \geq \epsilon) \leq P(\text{تخلی } \hat{h}^* \text{ از سمت چپ بیشتر از } \frac{\epsilon}{2} \text{ باشد} \cup \text{تخلی } \hat{h}^* \text{ از سمت راست بیشتر از } \frac{\epsilon}{2} \text{ باشد})$$

$$\stackrel{\text{union bound}}{\leq} 2(1 - \frac{\epsilon}{2})^m \leq 2e^{-\frac{m\epsilon}{2}}$$

sample complexity

$$m \geq \frac{2}{\epsilon} \lg \frac{2}{\delta}$$

7 ادله

چون sample complexity حالت disjoint بیشتر است آن را در نظر می گیریم.

در حالت اول که p بازه داشته باشیم $p-1$ تا ریسک از جنس R_3 داریم و $2p$ تا ریسک از جنس R_1 .
با تقسیم کردن ϵ به تعداد این بازه ها خواهیم داشت:

$$\mathbb{P}(R(\hat{\pi}^*) \geq \epsilon) \leq (2p) e^{-\frac{m\epsilon}{4p-2}} + (p-1) e^{-\frac{m\epsilon}{2p-1}} \leq (3p-1) e^{-\frac{m\epsilon}{4p-2}} \leq \delta$$

$$\rightarrow \text{sample complexity: } m \geq \frac{4p-2}{\epsilon} \lg \frac{3p-1}{\delta}$$

پیچیدگی زمانی الگوریتم نیز به خاطر مرتب سازی اولیه $O(m \lg m)$ است

8.a

تابع f خاصیت bounded difference property را دارد و هر x_i حلال $\frac{2M}{m}$ تغییر ایجاد می کند.

$$\text{Mc Diarmid} \rightarrow \mathbb{P}(|f(x) - \mathbb{E}[f(x)]| \geq \varepsilon) \leq 2e^{-\frac{2\varepsilon^2}{\sum c_i^2}}$$

$$\xrightarrow{c_i = \frac{2M}{m}} \mathbb{P}(|f(x) - \mathbb{E}[f(x)]| \geq \varepsilon) \leq 2e^{-\frac{2\varepsilon^2}{m \times \frac{4M^2}{m^2}}} = 2e^{-\frac{m\varepsilon^2}{2M^2}}$$

8.b

تابع h خاصیت bounded difference property را دارد و توان Mc Diarmid نوشت.
 فرض می کنیم $g(m) \in O(m^k)$ باشد و k را به نحوی پیدا کنیم که کران Mc Diarmid با افزایش m به صفر میل کند.

$$\xrightarrow{c_i = g(m) \in O(m^k)} \mathbb{P}(|h(x) - \mathbb{E}[h(x)]| \geq \varepsilon) \leq 2e^{-\frac{2\varepsilon^2}{\sum m^{2k}}} = 2e^{-\frac{2\varepsilon^2}{m \times m^{2k}}} = 2e^{-2\varepsilon^2 m^{-2k-1}}$$

برای اینکه این کران با افزایش m به 0 میل کند باید داشته باشیم $-2k-1 > 0 \leftarrow k < -\frac{1}{2}$
 یعنی سرعت نزول $g(m)$ باید بیشتر از $O(\frac{1}{\sqrt{m}})$ باشد مثلاً $O(m^{-(\frac{1}{2}+\delta)})$ ادکی است $\forall \delta > 0$

8.c

تابع f پایدار است زیرا $g(m) = \frac{2M}{m}$ که نزول می کند.
 چون $g(m) \in O(\frac{1}{m})$ پس قسمت قبل می دانیم که کران همگرا به صفر می شود.

$$\xrightarrow[\substack{\text{Mc Diarmid} \\ c_i = \frac{2M}{m}}]{\mathbb{P}(|f(x) - \mathbb{E}[f(x)]| \geq \varepsilon)} \leq 2e^{-\frac{2\varepsilon^2}{m \times \frac{4M^2}{m^2}}} = 2e^{-\frac{2m\varepsilon^2}{4M^2}}$$

ضریب f' با افزایش m نزول می کند و بنا بر این پایدار نیست.
 در این جا حد اکثر $2M$ تغییر می تواند ایجاد شود.

$$\xrightarrow[\substack{\text{Mc Diarmid} \\ c_i = 2M}]{\mathbb{P}(|f'(x) - \mathbb{E}[f'(x)]| \geq \varepsilon)} \leq 2e^{-\frac{2\varepsilon^2}{m \times 4M^2}}$$

همان طور که مشاهده می شود با افزایش m کران بهتر نمی شود و ضریب به دردی بخوری برای f' نیست.

9

اگر یک مسئله در معنای کلاسیک (تک ادراک) به طور کارآمد قابل یادگیری PAC باشد (zero-one = 0.5)

چون به طور کارآمد PAC learnable معنی پس تعلقاً یک \hat{h}^* ای توسط این الگوریتم به دست ما می‌رسد و تحلی آنرا $\frac{\epsilon}{2}$ در نظر می‌گیریم

$$R(\hat{h}^*) \leq \frac{\epsilon}{2} \quad n \geq \text{poly}\left(\frac{1}{\delta}, \frac{1}{\epsilon}\right)$$

$$\rightarrow \mathbb{E}_x[\ell(\hat{h}^*(x), h^*(x))] \leq \frac{\epsilon}{2}$$

$$\xrightarrow[\text{loss}]{\text{zero-one}} \mathbb{P}_x(\hat{h}^*(x) \neq h^*(x)) \leq \epsilon \rightarrow \mathbb{P}_x(\hat{h}^*(x) = 1, h^*(x) = 0) + \mathbb{P}_x(\hat{h}^*(x) = 0, h^*(x) = 1) \leq \frac{\epsilon}{2}$$

$$\rightarrow \mathbb{P}_x(\hat{h}^*(x) = 1 | h^*(x) = 0) \mathbb{P}_x(h^*(x) = 0) + \mathbb{P}_x(\hat{h}^*(x) = 0 | h^*(x) = 1) \mathbb{P}_x(h^*(x) = 1) \leq \frac{\epsilon}{2}$$

$$\mathbb{P}_x(h^*(x) = 0) \leftarrow \text{حال اگر فرض کنیم در مدل دو ادراک از هر کدام توزیع ها با احتمال برابر می‌گیریم خواهیم داشت}$$

$$= \mathbb{P}_x(h^*(x) = 1) = \frac{1}{2}$$

$$\rightarrow \mathbb{P}_x(\hat{h}^*(x) = 1 | h^*(x) = 0) + \mathbb{P}_x(\hat{h}^*(x) = 0 | h^*(x) = 1) \leq \epsilon$$

$$\mathbb{P}_x(\hat{h}^*(x) = 1 | h^*(x) = 0) \leq \epsilon \quad \mathbb{P}_{x \sim D^-}(\hat{h}^*(x) = 1) \leq \epsilon$$


$$\rightarrow \mathbb{P}_x(\hat{h}^*(x) = 0 | h^*(x) = 1) \leq \epsilon \quad \mathbb{P}_{x \sim D^+}(\hat{h}^*(x) = 0) \leq \epsilon$$

بنابراین از نوین efficiently PAC learnable بدون در حالت کلاسیک به تعریف efficiently PAC learnable بدون در حالت دو ادراک رسیدیم ✓

10

الگوریتم پیشنهادی ← کوکلیتین مستطیل n بُعدی که داده های trainset را در بر بگیرد، در نظر می گیریم

اثبات PAC learnability ← مستطیل های 2 بُعدی که سرکلاس \mathcal{H} را تقسیم می دهیم:



می دانیم که هر مستطیل axis aligned n بُعدی با $2n$ تا وجه دارند
 فرض می کنیم حجم ناحیه داخل h^* بیشتر از ϵ باشد چون اگر کمتر باشد already
 باید مد نظر را داریم. حال از هر وجه h^* به اندازه ای رو به داخل می گیریم که
 بریم احتمال آن ناحیه $\frac{\epsilon}{2n}$ شود. احتمال تحتی کل \hat{h}^* نسبت به h^* کمتر مساوی
 احتمال اجتماع تحتی هر وجه به اندازه $\frac{\epsilon}{2n}$ است. پس هر وجه را به صورت مستطیل
 و جدا در نظر می گیریم و می توان نوشت:

$$P(R(\hat{h}^*) \geq \epsilon) \leq P\left(\bigcup_{i=1}^{2n} E_i\right) \stackrel{\text{union bound}}{\leq} \sum_{i=1}^{2n} P(E_i) \leq \underbrace{P\left(\text{هیچ داده ای در بازه } \frac{\epsilon}{2n} \text{ نباشد}\right)}_{\left(1 - \frac{\epsilon}{2n}\right)^m}$$

$$\rightarrow P(R(\hat{h}^*) \geq \epsilon) \leq 2n \left(1 - \frac{\epsilon}{2n}\right)^m \leq 2n e^{-\frac{m\epsilon}{2n}} \leq \delta$$

$$\rightarrow \text{for } m \geq \frac{2n}{\epsilon} \lg \frac{2n}{\delta} \quad R(\hat{h}^*) \stackrel{1-\delta}{\geq} \epsilon$$

در برخی سوال ها با علی بابایی همکاری داشتیم