



تمرین دوم

مسئله ۱. وابستگی پیچیدگی راداماخر به توزیع (۱۰ نمره)

فرض کنید توزیع P را به گونه‌ای انتخاب کرده‌ایم که تک نقطه‌ای باشد یعنی $z = \delta(z_*)$ و نمونه‌ها از این توزیع می‌آیند. فرض کنید خانواده‌ی \mathcal{F} را به گونه‌ای انتخاب کرده‌ایم که برای هر $x \in \mathbb{R}$ و $f \in \mathcal{F}$ ، $-1 \leq f(x) \leq 1$. نشان دهید که:

$$\mathcal{R}_n(\mathcal{F}) \leq \frac{1}{\sqrt{n}}$$

حل.

$$\begin{aligned} \mathcal{R}_n(\mathcal{F}) &= \mathbb{E}_{z_1, \dots, z_n} \mathbb{E}_{\sigma_1, \dots, \sigma_n} \frac{1}{n} \sup_{f \in \mathcal{F}} \sum_{i=1}^n \sigma_i f(z_i) \\ &= \mathbb{E}_{\sigma_1, \dots, \sigma_n} \frac{1}{n} \sup_{f \in \mathcal{F}} f(z_*) \sum_{i=1}^n \sigma_i \\ &\leq \mathbb{E}_{\sigma_1, \dots, \sigma_n} \frac{1}{n} \sup_{f \in \mathcal{F}} |f(z_*)| \sum_{i=1}^n |\sigma_i| \leq \mathbb{E}_{\sigma_1, \dots, \sigma_n} \frac{1}{n} \sqrt{\sum_{i=1}^n \sigma_i^2} = \frac{1}{\sqrt{n}} \end{aligned}$$

▷

مسئله ۲. خواص بعد VC (۱۵ نمره)

بعد VC یک خانواده از مجموعه‌های \mathcal{S} را برابر بعد VC توابع به شکل 1_S تعریف می‌کنیم که $S \in \mathcal{S}$. فرض کنید \mathcal{S}, \mathcal{T} دو خانواده از مجموعه‌ها با بعد VC محدود باشند نشان دهید خانواده‌های زیر نیز بعد VC محدود دارند:

(الف)

$$\mathcal{S}^c := \{S^c | S \in \mathcal{S}\}$$

(ب)

$$\mathcal{S} \cap \mathcal{T} = \{S \cap T | S \in \mathcal{S}, T \in \mathcal{T}\}$$

(ج)

$$\mathcal{S} \sqcup \mathcal{T} = \{S \cup T | S \in \mathcal{S}, T \in \mathcal{T}\}$$

حل.

الف) اگر S بتواند یک مجموعه‌ی n عضوی را shatter کند S^c نیز می‌تواند این مجموعه را shatter کند و بالعکس (کافیست لیبل‌های برعکس را در نظر بگیریم و این ترکیب را بسازیم و آن را مکمل بگیریم) که نتیجه می‌دهد که بعد VC هر دو S و S^c یکسان است.

ب) فرض کنید بعد VC S, T به ترتیب برابر μ, ν باشد در این صورت در یک مجموعه‌ی n عضوی هر کدام به ترتیب $(n+1)^\mu$ و $(n+1)^\nu$ ترکیب را تولید می‌کنند و لذا در کل تعداد ترکیب‌هایی که با اشتراک این‌ها می‌توان تولید کرد برابر است با:

$$(n+1)^{\mu+\nu}$$

و لذا اگر n را به گونه‌ای انتخاب کنیم که:

$$(n+1)^{\mu+\nu} < 2^n$$

آنگاه یک مجموعه‌ی n عضوی را نمی‌توان با اشتراک اعضای S و T shatter کرد.

ج) مشابه قبلی :

▷

مسئله‌ی ۳. خواص پیچیدگی راداماخر (۱۵ نمره)

خواص زیر از پیچیدگی راداماخر را ثابت کنید:

الف)

$$\mathcal{R}_n(\mathcal{F}) = \mathcal{R}_n(\text{conv}(\mathcal{F}))$$

ب)

$$\mathcal{R}_n(\mathcal{F} + \mathcal{G}) \leq \mathcal{R}_n(\mathcal{F}) + \mathcal{R}_n(\mathcal{G})$$

و مثالی ارائه دهید که نتوان کران را بهبود داد.

ج) برای تابع ثابت و کراندار g :

$$\mathcal{R}_n(\mathcal{F} + g) \leq \mathcal{R}_n(\mathcal{F}) + \frac{\|g\|_\infty}{\sqrt{n}}$$

حل.

الف) کافیت توجه کنیم که:

$$\sup_{f \in \mathcal{F}} \sum_{i=1}^n f(z_i) \sigma_i = \sup_{f \in \text{conv}(\mathcal{F})} \sum_{i=1}^n f(z_i) \sigma_i$$

برای اثبات فرض کنیم مقدار بالا برای $\sum_{j=1}^m \alpha_j f_j$ بیشینه گردد در این صورت این ضرب داخلی برای همه‌ی f_j ها باید یکسان باشد (در غیر این صورت اگر ضریب آن را صفر کنیم عبارت بیشتر می‌گردد) و کافیت آن f را برای بیشینه کردن روی \mathcal{F} در نظر بگیریم.

ب) از خاصیت زیر برای \sup نتیجه می‌گردد که در کلاس اثبات شد:

$$\sup_{x \in \mathcal{X}} f(x) + g(x) \leq \sup_{x \in \mathcal{X}} f(x) + \sup_{x \in \mathcal{X}} g(x)$$

ج)

$$\begin{aligned} \mathcal{R}_n(\mathcal{F} + g) &= \mathbb{E}_{z_1, \dots, z_n} \mathbb{E}_{\sigma_1, \dots, \sigma_n} \frac{1}{n} \sup_{f \in \mathcal{F}} \sum_{i=1}^n (f(z_i) + g(z_i)) \sigma_i \\ &\leq \mathbb{E}_{z_1, \dots, z_n} \mathbb{E}_{\sigma_1, \dots, \sigma_n} \frac{1}{n} \sup_{f \in \mathcal{F}} \sum_{i=1}^n f(z_i) \sigma_i + \|g\|_{\infty} \sum_{i=1}^n \sigma_i \end{aligned}$$

از طرفی بنابر نابرابرینسن داریم:

$$\mathbb{E}_{\sigma_1, \dots, \sigma_n} \sum_{i=1}^n \sigma_i \leq \sqrt{\mathbb{E}_{\sigma_1, \dots, \sigma_n} \sum_{i=1}^n \sigma_i^2} = \sqrt{n}$$

و حکم نتیجه می‌گردد.

▷

مسئله‌ی ۴. محاسبه بعد VC (۱۰ نمره)

بعد VC مجموعه‌های زیر را حساب کنید:

الف) مجموعه دایره‌های در صفحه.

ب) مجموعه مربع‌های در صفحه.

حل.

الف) اول دایره ها می توانند هر سه نقطه‌ی غیر هم خط را shatter کنند. زیرا می توان شعاع دایره را به اندازه کافی زیاد کرد تا مشابه یک خط باشد و می دانیم که با خط ها می توان سه نقطه‌ی غیر هم خط را shatter کرد. برای اثبات این که هیچ ۴ نقطه‌ای را نمی توان با این دایره ها shatter کرد کافیت توجه کنیم که اگر پوش محدب این نقاط شامل سه نقطه باشد کافیت نقطه‌ی داخل پوش محدب را منفی و بقیه را مثبت کنیم در غیر این صورت circle minimum-enclosing را در نظر می گیریم اگر دو نقطه‌ی روبه‌رو قطری روی آن بود و دو نقطه‌ی دیگر در دو سمت مختلف قطر حضور داشتند کافیت دو نقطه‌ی روی قطری را مثبت و دو تای دیگر را منفی کنیم. اگر هر دو یک سمت قطر بودند آن نقطه‌ی که همراه با دو نقطه روی قطر دایره‌ی محیطی کوچکتری را تشکیل می دهد را مثبت و سایر را منفی می کنیم و اگر سه نقطه روی این دایره بودند کافیت دو نقطه مقابل در پوش محدب که هر دو روی دایره هستند را مثبت و سایر را منفی کنیم.

ب) مشابه قبلی

▷

مسئله‌ی ۵. SVM تنک (۱۵ نمره)

یکی دیگر از روش های فرموله کردن الگوریتم SVM، بر پایه تنکی (sparsity) بردارهای کمکی است. فرض کنید به جای بیشینه کردن مقدار حاشیه می خواهیم تنکی بردارها را بیشینه کنیم. این کار را با کمینه کردن $\|\alpha\|_p$ که با آن بردار w به دست می آید انجام می دهیم ($p \geq 1$). ابتدا حالتی را در نظر بگیرید که $p = 2$. به مساله بهینه سازی زیر می رسم:

$$\begin{aligned} \min_{\alpha, b} \quad & \frac{1}{2} \sum_{i=1}^m \alpha_i^2 + C \sum_{i=1}^m \xi_i \\ \text{subject to} \quad & y_i \left(\sum_{j=1}^m \alpha_j y_j \mathbf{x}_i \cdot \mathbf{x}_j + b \right) \geq 1 - \xi_i, \quad i \in [m] \\ & \xi_i, \alpha_i \geq 0, \quad i \in [m]. \end{aligned}$$

الف) نشان دهید که با در نظر گرفتن قید نامنفی بودن برای α این مسئله را می توانیم به یک نمونه از مسئله اولیه SVM تبدیل کنیم.

ب) مساله بهینه سازی دوگان مساله بالا را بنویسید.

ج) اگر قرار دهیم $p = 1$ ، به یک α تنک تر دست می یابیم. مساله دوگان را در این حالت به دست آورید.

حل. الف) فرض کنید

$$\mathbf{x}'_i = (y_1(\mathbf{x}_1 \cdot \mathbf{x}_i), \dots, y_m(\mathbf{x}_m \cdot \mathbf{x}_i)).$$

سپس مسئله بهینه سازی به صورت زیر خواهد بود:

$$\min_{\alpha, b, \xi} \quad \frac{1}{2} \|\alpha\|^2 + C \left(\sum_{i=1}^m \xi_i \right)$$

با قيود زیر:

$$y_i(\alpha \cdot \mathbf{x}'_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \alpha_i \geq 0, \quad i \in [m].$$

(ب) متغیر های لاگرانژ زیر را تعریف میکنیم و مساله لاگرانژین را می نویسیم:

$$p_i, q_i, r_i \geq 0$$

$$L(\alpha, b, \xi, p, q, r) = \frac{1}{2} \|\alpha\|^2 + C \left(\sum_{i=1}^m \xi_i \right) - \sum_{i=1}^m p_i \left\{ y_i \left[\left(\sum_{j=1}^m \alpha_j y_j x_j \right) \cdot x_i + b \right] - 1 + \xi_i \right\} \\ - \sum_{i=1}^m q_i \xi_i - \sum_{i=1}^m r_i \alpha_i.$$

پس از برابر قرار دادن گرادیان عبارت بالا نسبت به متغیر های primal با صفر داریم:

$$L(\alpha, b, \xi, p, q, r) = \frac{1}{2} \|\alpha\|^2 + C \left(\sum_{i=1}^m \xi_i \right) - \sum_{i=1}^m \alpha_i (\alpha_i - r_i) - \sum_{i=1}^m p_i y_i b - \sum_{i=1}^m p_i - \sum_{i=1}^m (p_i + q_i) \xi_i - \sum_{i=1}^m r_i \alpha_i \\ = -\frac{1}{2} \left(\sum_{i=1}^m p_i y_i x_i \right)^2 + \sum_{i=1}^m p_i.$$

پس در نهایت با قرار دادن عبارات کنار هم داریم:

$$\max_{p, r} \sum_{i=1}^m p_i - \frac{1}{2} \left\| \sum_{i=1}^m p_i y_i x_i + r \right\|^2$$

$$\text{subject to } 0 \leq p_i \leq C \quad \forall i, \quad \sum_{i=1}^m p_i y_i = 0, \quad r \in \mathbb{R}.$$

(ج) راه حل این قسمت بسیار مشابه قسمت ب است با این تفاوت که عبارت

$$\frac{1}{2} \|\alpha\|^2$$

با عبارت

$$\|\alpha\|_1 = \sum_{i=1}^m |a_i|$$

▷

جایگزین خواهد شد و از تکرار راه حل صرف نظر می کنیم.

مسئله ۶. قضیه رادون (۱۰ نمره)

برای مجموعه $S = \{\mathbf{x}_1, \dots, \mathbf{x}_m | \forall i \in [m] : \mathbf{x}_i \in \mathbb{R}^n\}$ ، پوش محدب S مجموعه ای است به صورت:

$$\{\mathbf{z} \in \mathbb{R}^n \mid \exists \lambda_1, \dots, \lambda_m \in [0, 1], \sum_{i=1}^m \lambda_i = 1, \mathbf{z} = \sum_{i=1}^m \lambda_i \mathbf{x}_i\}.$$

اگر $m \geq n + 2$ ، ثابت کنید S دارای دو زیرمجموعه مجزا S_1 و S_2 است که پوش محدب آنها تداخل دارد.

حل. لم: اگر $P = \{p_1, \dots, p_n\} \subset \mathbb{R}^d$ مجموعه ای متناهی از نقاط در فضای d -بعدی باشد، اگر $n > d$ ، آنگاه برای بعضی ضرایب μ_1, \dots, μ_n داریم:

$$0 = \sum_{i=1}^n \mu_i p_i \quad \text{with} \quad \mu_1, \dots, \mu_n \text{ not all zero,}$$

و اگر $n > d + 1$ ، می توانیم عبارت بالا را با شرط اضافی

$$\sum_{i=1}^n \mu_i = 0.$$

داشته باشیم. در حالت دوم، بعضی از μ_1, \dots, μ_n مثبت و بعضی منفی هستند.

اثبات: اگر $n = d + 2$ و $P = \{p_1, \dots, p_n\} \subset \mathbb{R}^d$ ، طبق لم بالا، برای ضرایب μ_1, \dots, μ_n (که بعضی مثبت و بعضی نامنفی هستند) داریم:

$$0 = \sum_{i=1}^n \mu_i p_i \quad \text{with} \quad \sum_{i=1}^n \mu_i = 0.$$

قرار دهید $J = \{j \in \{1, \dots, n\} : \mu_j > 0\}$ و $I = \{1, \dots, n\} \setminus J$. نه J و نه I تهی نیستند. قرار دهید

$$A = \sum_{j \in J} \mu_j \quad \text{که} \quad A > 0.$$

پس

$$\sum_{i \in I} \mu_i = -A.$$

قرار دهید $P_1 = \{p_j : j \in J\}$ ، $P_2 = \{p_i : i \in I\}$. پوش محدب $\text{Conv}(P_1)$ ، $\text{Conv}(P_2)$ شامل نقطه

$$p = \sum_{j \in J} \frac{\mu_j}{A} x_j = \sum_{i \in I} \frac{-\mu_i}{A} x_i,$$

است چرا که حاصل جمع اول یک ترکیب محدب از نقاط P_1 و حاصل جمع دوم ترکیب محدب از نقاط P_2 است.

پس،

$$\text{Conv}(P_1) \cap \text{Conv}(P_2) \neq \emptyset.$$

▷

مسئله ۷. مثال نقض (۱۰ نمره)

اغلب این‌گونه است که بُعد VC یک کلاس فرضیه برابر (یا از بالا محدود شونده) با تعداد پارامترهایی است که برای تعریف هر فرضیه در کلاس نیاز است. برای مثال، اگر \mathcal{H} کلاس مستطیل‌های هم‌تراز با محور در \mathbb{R}^d باشد، آنگاه $VCdim\mathcal{H} = 2d$ است که برابر با تعداد پارامترهای مورد نیاز برای تعریف مستطیلی در \mathbb{R}^d می‌باشد. در اینجا مثالی وجود دارد که نشان می‌دهد این همیشه درست نیست. ما خواهیم دید که یک کلاس فرضیه می‌تواند بسیار پیچیده باشد و حتی یادگیری‌پذیر نباشد، اگرچه تعداد کمی پارامتر دارد.

دامنه $\mathcal{X} = \mathbb{R}$ و کلاس فرضیه

$$\mathcal{H} = \{x \mapsto \lceil \sin(\theta x) \rceil : \theta \in \mathbb{R}\}$$

را در نظر بگیرید. (اینجا، $\lceil -1 \rceil = 0$ را می‌گیریم). اثبات کنید که $VCdim\mathcal{H} = \infty$.

نکته: راه‌های متعددی برای اثبات این نتیجه وجود دارد. یک راه با اعمال لم زیر است: اگر $x_1 x_2 x_3 \dots$ بسط دودویی $(0, 1)$ باشد، آنگاه برای هر عدد طبیعی m ، $\lceil \sin(2^m \pi x) \rceil = (1 - x_m)$ ، به شرطی که $\exists k \geq m$ که در آن $x_k = 1$.

حل. ابتدا لم مطرح شده را اثبات می‌کنیم:

$$\begin{aligned} \sin(2^m \pi x) &= \sin(2\pi(0.x_1 x_2 \dots)) = \sin(2\pi(x_1 x_2 \dots x_{m-1} x_m x_{m+1} \dots)) \\ &= \sin(2\pi(x_1 x_2 \dots x_{m-1} x_m x_{m+1} \dots) - 2\pi(x_1 x_2 \dots x_{m-1} / 0)) = \sin(2\pi(0.x_m x_{m+1} \dots)). \end{aligned}$$

حال، اگر $x_m = 0$ ، آنگاه $2\pi(0.x_m x_{m+1} \dots) \in (0, \pi)$ ، پس عبارت بالا مثبت است و، $\lceil \sin(2^m \pi x) \rceil = 1$. همچنین، اگر $x_m = 1$ ، آنگاه $2\pi(0.x_m x_{m+1} \dots) \in [\pi, 2\pi)$ ، پس عبارت بالا نامثبت است و، $\lceil \sin(2^m \pi x) \rceil = 0$. در نتیجه داریم:

$$\lceil \sin(2^m \pi x) \rceil = 1 - x_m.$$

برای اینکه ثابت کنیم $VC(\mathcal{H}) = \infty$ ، باید n نقطه انتخاب کنیم که توسط $\text{shatter}\mathcal{H}$ می‌شوند، برای هر n . پس، n نقطه $x_1, \dots, x_n \in [0, 1]$ می‌سازیم، به گونه‌ای که مجموعه بیت m -ام در نمایش باینری، وقتی که m از 1 تا 2^n تغییر می‌کند، روی تمام حالات labeling x_1, \dots, x_n تغییر می‌کند:

$$x_1 = 0.0000\dots 11$$

$$x_2 = 0.0000\dots 11$$

$$\vdots$$

$$x_{n-1} = 0.0011\dots 11$$

$$x_n = 0.0100\dots 01$$

برای مثال برای آنکه لیبل 1 برای همه نمونه‌ها را بسازیم، $h(x) = \lceil \sin(2^1 x) \rceil$ را انتخاب می‌کنیم، که اولین بیت یا ستون از بسط باینری را می‌سازد. اگر بخواهیم لیبل 1 برای x_1, \dots, x_{n-1} و لیبل 0 برای x_n داشته باشیم، $h(x) = \lceil \sin(2^2 x) \rceil$ را انتخاب می‌کنیم، که بیت دوم از بسط باینری را می‌سازد و به همین ترتیب می‌توان ادامه داد.

پس نتیجه میگیریم که x_1, \dots, x_n میتواند هر labeling برای برخی مقادیر $h \in \mathcal{H}$ را تولید کند، پس. شده shatter. این کار را میتوان برای هر n انجام داد، پس $\text{VCdim}(\mathcal{H}) = \infty$.
 \triangleright

مسئله ۸. رأی اکثریت (۱۵ نمره)

نشان دهید که اگر کلاس فرضیه \mathcal{H} دارای VC-dimension برابر d باشد، آنگاه کلاس $\text{MAJ}_k(\mathcal{H})$ دارای VC-dimension برابر $O(kd \log kd)$ است. منظور از $\text{MAJ}_k(\mathcal{H})$ کلاس توابعی است که با گرفتن رأی اکثریت بر روی k تابع از \mathcal{H} به دست می‌آید.

حل. فرض کنید D ، VC-dimension $\text{MAJ}_k(\mathcal{H})$ باشد، پس طبق تعریف، وجود دارد مجموعه S متشکل از D نقطه که با $\text{MAJ}_k(\mathcal{H})$ shatter شده. طبق لم ساور میدانیم که حداکثر D^d روش دسته بندی نقاط S با استفاده از توابع \mathcal{H} وجود دارد.

حال چون هر تابع h در $\text{MAJ}_k(\mathcal{H})$ با برخی k تابع h_1, h_2, \dots, h_k در \mathcal{H} مشخص شده، این یعنی دسته بندی S توسط h با دسته بندی S توسط h_1, \dots, h_k مشخص شده. چون ما کسیم $(D^d)^k = D^{dk}$ حالت انتخاب k دسته بندی از S مطابق با \mathcal{H} وجود دارد (احتمالا با تکرار)، این یعنی حداکثر D^{kd} حالت دسته بندی نقاط S با استفاده از توابع $\text{MAJ}_k(\mathcal{H})$ وجود دارد.

از طرفی، چون S توسط $\text{shatterMAJ}_k(\mathcal{H})$ شده، میدانیم همه 2^D دسته بندی ممکن هستند. در نتیجه داریم

$$2^D \leq D^{kd},$$

\triangleright

و $D \leq 2kd \log(kd)$ (برای $kd \geq 4$).