



نظریه یادگیری ماشین

نیم سال اول ۱۴۰۳-۱۴۰۴

مدرس: دکتر امیر نجفی

تمرین چهارم

مسئله ۱. رگرسیون محدب (۱۰ نمره)

فرض کنید می‌خواهیم مسئله رگرسیون به شکل زیر را حل کنیم:

$$\min_{f \in \mathcal{F}} \sum_{i=1}^n (f(x_i) - y_i)^2$$

که در اینجا \mathcal{F} مجموعه همه توابع محدب است. روشی برای حل این مسئله بهینه‌سازی نامتناهی بعدی ارائه دهید. (نکته جالب: برخلاف حالت classification این مسئله قابل یادگیری است)

مسئله ۲. به‌روزرسانی وزن‌ها (۱۵ نمره)

فرض کنید که فرض main weak learner در الگوریتم AdaBoost برقرار باشد. فرض کنید h_t یادگیرنده پایه‌ای باشد که در مرحله t انتخاب شده است. نشان دهید که یادگیرنده پایه h_{t+1} که در مرحله $t + 1$ انتخاب شده است باید متفاوت از h_t باشد.

مسئله ۳. لاسو گروهی با گروه‌های همپوشان (۱۵ نمره)

نشان دهید اگر از لاسو گروهی برای گروه‌های همپوشان استفاده کنیم در این که پارامترهای غیر صفر ما در اجتماعی از این گروه‌ها قرار بگیرند کمکی نمی‌کند. به طور دقیق‌تر استفاده از این هموارساز باعث می‌شود که پارامترها در مکمل اجتماعی از این گروه‌ها قرار بگیرند. (نیازی به اثبات این مورد نیست، برای حل این مشکل Overlapping group lasso طراحی شده است که می‌توانید در مورد آن بیشتر بخوانید.

مسئله ۴. در جستجوی هموارساز خوب (۱۰ نمره)

در دو کرانی که برای پیچیدگی راداماکس مدل‌های خطی به دست آوردیم دو عبارت ظاهر می‌شد:

الف) برای نرم ۱ عبارتی که ظاهر می‌شد برابر $\|w\|_1 \|x\|_\infty$ بود (در واقع کران‌هایی روی این‌ها ولی برای سادگی فعلاً این عبارت‌ها را در نظر می‌گیریم).

ب) برای نرم ۲ عبارت $\|w\|_2 \|x\|_2$ ظاهر می‌شد.

فرض کنید w, x متغیرهای تصادفی نزدیک مقادیر $\{-1, 1\}$ باشند. در حالت‌های زیر این دو کران را بررسی کنید و نتیجه بگیرید هموارسازی با نرم ۱ و ۲ چه زمان‌هایی مناسب‌تر هستند.

الف) بدون هیچ فرض اضافه‌ای.

ب) w تنک با حداکثر k مولفه ناصفر باشد.

ج) w چگال باشد مثلاً با فرض $\|w\|_2 \approx \sqrt{d}\|w\|_1$

مسئله‌ی ۵. خطای نمایی Bayes (۱۵ نمره)

فرض کنید مجموعه ورودی \mathcal{X} و فضای برچسب $Y = \{-1, +1\}$ باشد. در الگوریتم AdaBoost از تابع خطای نمایی زیر استفاده می‌شود:

$$\ell(h(x), y) = \exp(-yh(x)).$$

برای یک توزیع \mathcal{D} روی $\mathcal{X} \times Y$ ، خطای نمایی به صورت زیر تعریف می‌شود:

$$R_l(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\ell(h(x), y)].$$

خطای نمایی بیز برای یک توزیع \mathcal{D} به صورت خطای کمینه روی توابع قابل اندازه‌گیری تعریف می‌شود:

$$R_l^* = \inf_{h: \mathcal{X} \rightarrow \mathbb{R} \text{ measurable}} R_l(h).$$

فرضیه‌ای h_{exp} با $R_l(h_{\text{exp}}) = R_l^*$ به عنوان راه حل بهینه بیز نامیده می‌شود. $\eta(x) = P[y = \text{صورت} | x]$ را به صورت $\eta(x) = P[y = \text{صورت} | x]$ تعریف کنید.

(a) عبارت رابطه راه حل بهینه بیز h_{exp} را برای خطای نمایی بر حسب $\eta(x)$ بدهید.

(b) خطای generalization و خطای بیز برای طبقه‌بندی باینری را به صورت زیر تعریف کنید:

$$R(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\mathbb{I}[\text{sign}(h(x)) \neq y]], \quad R^* = \inf_{h: \mathcal{X} \rightarrow \mathcal{Y} \text{ measurable}} R(h).$$

$$\text{sign}(t) = \mathbb{I}_{t \geq 0} - \mathbb{I}_{t < 0}.$$

$$R(h_{\text{exp}}) = R^* \text{ نشان دهید}$$

مسئله‌ی ۶. خطای طبقه‌بند ضعیف (۱۰ نمره)

نشان دهید خطای h_t با توجه به توزیع $D^{(t+1)}$ دقیقاً برابر با $1/2$ است. به عبارت دیگر، نشان دهید که برای هر $t \in [T]$ داریم:

$$\sum_{i=1}^m D_i^{(t+1)} \mathbb{I}[y_i \neq h_t(x_i)] = \frac{1}{2}.$$