


Exp is memoryless

$$\mathbb{P}(X \geq t+s) = e^{-\lambda(t+s)}$$

$$\mathbb{P}(X \geq t+s | X \geq t) = \mathbb{P}(X \geq s) = e^{-\lambda s}$$

#

$$\mathbb{P}(X \geq t+s)$$



⊗ موقعیت کم داشت R.V. \rightarrow
 که فقط با X بودست میان نسبت به تمام Y بودست
 میان میان باشند

Binomial.


$$X, Y \sim \text{Bern}(\rho), \text{Bern}(\tilde{\rho}) \quad \tilde{\rho} = \frac{k}{n}$$

$$\rho(\tilde{\rho}) \propto \frac{e^{-n} D_{KL}(\tilde{\rho} || \rho)}{\sqrt{2\pi n \tilde{\rho}(1-\tilde{\rho})}}$$


اگر $\tilde{\rho}$ کوچک حل peak & سینه کوچک میشود

$$D_{KL}(\tilde{\rho} || \rho) \triangleq \tilde{\rho} \lg \frac{\tilde{\rho}}{\rho} + (1-\tilde{\rho}) \lg \frac{1-\tilde{\rho}}{1-\rho}$$

Geometric = discrete version of Exp



Bernoulli process



⊗ تغیر تصادفی و صورت (ω) X می نویسیم ولی فرآیند تصادفی و ب صورت $X(\omega, t)$ می نویسیم، این هر ω پنجایی یک عدد، یک sample path است

⊗ تصادفی randomness در ω نه و بعد از بخ دادن اون t_i ها صورت deterministic است و هر جسمی که از ω میگیرد

$\omega \equiv \text{seed} \leftarrow \text{use } \omega \text{ to } t_i$

⊗ فرآیند تصادفی معادل joint R.V. هاست بی خاتمه


random vector

⊗ ترکیب تصادفی یا باید مولس نامحدود باشیم یا اگر محدود باید مولس خود را تصادفی باشیم. در عین این صورت بحث میگردد

Bernoulli process

View 1 $\{z_i \mid i \in \mathbb{N}\}$ $z_1, \dots \stackrel{iid}{\sim} \text{Bern}(p)$

View 2 $\{S_i \mid i \in \mathbb{N}\}$ $S_i = \sum_{j=1}^i z_j$ $S_1, \dots \stackrel{iid}{\sim} \text{Binom}$



View 3 $\{X_i \mid i \in \mathbb{N}\}$ $X_1, \dots \stackrel{iid}{\sim} \text{Geom}(p)$

دیرگی دار
از زمان t_1 بعد و نسون مون بعنوان فحیم $(0, t_1)$ بپرسید شد پوچ
اگر جهت زمان «برگردان کن» صهیان فریاد بردهای خواهد شد
ذینکه memory less اینکه x_i بازگشت زمان x_{i+1} ایجاد شد x_i ← memory less

Expectation

Moments

Keyview

MGF

Concentration Inequalities

Laws of Large Numbers

دایرکت و تابعی
و تابعی

$$X_1, \dots, X_n \stackrel{iid}{\sim} f_X(x) \quad E[X] = \mu$$

CLT

دایرکت و تابعی

$$Z_n \triangleq \frac{S_n - n\mu}{\sigma\sqrt{n}}$$

$$S_n \triangleq X_1 + \dots + X_n$$

$$\lim_{n \rightarrow \infty} Z_n \sim N(0, 1)$$

$$\text{weak LLN} \quad \lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - \mu\right| > \varepsilon\right) = 0$$

I.O.

$$\text{strong LLN} \quad P\left(\lim_{n \rightarrow \infty} \frac{S_n}{n} = \mu\right) = 1$$

convergence

$$X \sim N(0, \sigma^2)$$

$$E[X^{2k}] = \frac{(2k)!}{k! 2^k} \sigma^{2k} \quad k=1, \dots$$

این که X را R.V. گوییم Memoryless X is memoryless if


$$\begin{aligned} p(X \geq t + \delta) &= p(X \geq t) p(X \geq \delta) \\ &\equiv \\ p(X \geq t + \delta \mid X \geq t) &= p(X \geq t) \end{aligned}$$

Convergence in Distribution

Sequence z_1, \dots converges in distribution to z^* if

$$\lim_{n \rightarrow \infty} F_{z_n}(z) = F_{z^*}(z) \quad \forall z \text{ for which } F_{z^*}(z) \text{ is continuous}$$

$$\text{e.g. CLT} \longrightarrow \lim_{n \rightarrow \infty} \mathbb{P}(z_n < n) = \mathbb{P}(N(0,1) < n) \\ \forall n \in \mathbb{R}$$



Convergence in probability

Sequence z_1, \dots converges in probability to z^* if

$$\lim_{n \rightarrow \infty} \mathbb{P}(|z_n - z^*| > \varepsilon) = 0 \quad \forall \varepsilon > 0$$

$$\text{e.g. weak LLN} \longrightarrow \lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{s_n}{n} - \mu\right| > \varepsilon\right) = 0 \quad \forall \varepsilon > 0$$

اللهم الاختلاف ينبع من التباين في الاعداد المئوية المتباعدة \Rightarrow CLT

Convergence in Mean Square

Sequence z_1, \dots converges in mean square to z^* if

$$\lim_{n \rightarrow \infty} E[(z_n - z^*)^2] = 0$$

Convergence with probability 1 (a.s.)

Sequence z_1, \dots converges with probability 1 to z^* if

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} z_n(\omega) = z^*(\omega) \mid \omega \in \Omega\right) = 1$$

\equiv

$$\lim_{n \rightarrow \infty} z_n \xrightarrow{\text{a.s.}} z^*$$

$$\text{e.g. strong LLN} \longrightarrow \mathbb{P}\left(\lim_{n \rightarrow \infty} \frac{s_n(\omega)}{n} = \mu\right) = 1$$

poisson process

point process, Arrival process

A renewal process over \mathbb{R} where $X_1, \dots \stackrel{iid}{\sim} \lambda e^{-\lambda n} u(n)$
for some fixed $\lambda > 0$

rate

برتره

: to Arrival process ایجاد نسخه دادن

- $\{X_i | i \in \mathbb{N}\}$ inter arrival periods

- Memory less property

$$P(X_i > t + \delta | X_i > t) = P(X_i > \delta)$$

- $\{S_n | n \in \mathbb{N}\}$ epoch این n نسل

new arrival

$$S_n = \sum_{i=1}^n X_i$$


- stationary Increment property

A counting process $\{N(t) | t \geq 0\}$

has this property if $\frac{N(t') - N(t)}{t' - t}$


has the same CDF as

$$N(t' - t) \quad \forall t' > t \geq 0 \quad \text{اگر } t' \text{ ایجاد شد} \quad (t, t')$$



⊕ هر دو تابع دلخواه، صور آن احتمال داریت پاسن، شد
arrival times که توزیع رخ میده، هم توزیع هست آن طبق
باشه ما یکسان باش

- $\{S_n \leq t\} \equiv \{N(t) \geq n\} \quad \forall n \in \mathbb{N} \quad t \geq 0$



- Independent Increment property

$$\tilde{N}(t, t') \triangleq N(t') - N(t) \quad \begin{array}{c} \text{hatched} \\ t \quad t' \end{array}$$

We have this property if for all $n \geq 2$,
 $0 < t_1 < \dots < t_n \in \mathbb{R}$

$$N(t_1), \tilde{N}(t_1, t_2), \dots, \tilde{N}(t_{n-1}, t_n)$$

are independent

Renewal process is a type of arrival process
where inter arrival periods X_1, \dots are iid

⊕ در فرایند های دلخواه دو نوع دارد
در فرایند های پرسانه فقط پرسانه است
non memoryless

⊕ فرایند پرسانه هم time reversible

⊕ ایجاد شده، میخواهیم اطلاعات نسبت به تعداد
ایجاد شده های باشه های دلخواه ایجاد شده
(باشه های بدون احتمال)

$$f_{S_n}(s_n)$$

$$s_n = \sum_{i=1}^n x_i \quad \text{Var}(s_n) = \frac{n}{\lambda^2} \quad E[s_n] = \frac{n}{\lambda}$$


$$s_1 = x_1 \sim \lambda e^{-\lambda n} u(n)$$

$$\begin{aligned} s_2 = x_1 + x_2 &\sim (f_x * f_x)(n) = \int_{-\infty}^{\infty} \lambda e^{-\lambda t} u(t) \lambda e^{-\lambda(n-t)} u(n-t) dt \\ &= \lambda^2 e^{-\lambda n} \underbrace{\int_{-\infty}^{\infty} u(t) u(n-t) dt}_{\delta_{\lambda}^n dt} = \lambda^2 n e^{-\lambda n} u(n) \end{aligned}$$

⋮

$$s_n = x_1 + \dots + x_n \sim \frac{\lambda^n n^{n-1}}{(n-1)!} e^{-\lambda n} u(n)$$

Erlang's distribution



λ usually denotes rate or exponent

$$f_{s_1 \dots s_n}(s_1, \dots, s_n)$$

$$0 < s_1 < \dots < s_n$$

$$f_{s_1}(s_1) = \lambda e^{-\lambda s_1} u(s_1)$$

$$f_{s_1 s_2}(s_1, s_2) = f_{s_1}(s_1) f_{s_2 | s_1}(s_2 | s_1) = \lambda^2 e^{-\lambda s_2} u(s_1) u(s_2 - s_1)$$

$$\lambda e^{-\lambda s_1} u(s_1) \quad \lambda e^{-\lambda(s_2 - s_1)} u(s_2 - s_1)$$

(memoryless property)

s_1 توزيع دوري و s_2 توزيع دوري \oplus
متوزع كثافة بين $(0, s_2)$ توزيع دوري \oplus

متوزع دوري s_2 توزيع دوري و s_1 توزيع دوري \oplus

$$f_{s_1 \dots s_n}(s_1 \dots s_n) = \lambda^n e^{-\lambda s_n} \mathbb{1}(0 < s_1 < \dots < s_n)$$


$$f_{s_n}(s_n) = \int_0^{s_n} \int_0^{s_{n-1}} \dots \int_0^{s_2} \lambda^n e^{-\lambda s_n} ds_1 \dots s_{n-1}$$

$$= \lambda^n e^{-\lambda s_n} \frac{s_n^{n-1}}{(n-1)!}$$

area

$$\int_0^{s_2} ds_1 = s_2 - s_1 = s_2$$

$$\int_0^{s_3} \int_0^{s_2} ds_1 ds_2 = \frac{s_3^2}{2}$$



$$f_{s_1, \dots, s_{n-1} | s_n}(s_1, \dots, s_{n-1} | s_n) = \frac{\lambda^n e^{-\lambda s_n} \mathbb{1}(0 < s_1 < \dots < s_n)}{\lambda^n s_n^{n-1} e^{-\lambda s_n}} = \frac{(n-1)!}{s_n^{n-1}} \mathbb{1}(0 < s_1 < \dots < s_n)$$

uniform $(0, s_n)$

$$f_{s_n | s_1, \dots, s_{n-1}}(s_n | s_1, \dots, s_{n-1}) = \lambda e^{-\lambda(s_n - s_{n-1})} u(s_n - s_{n-1})$$

exponential

* مرآینه بواسون \longleftrightarrow در هر باره (بازه ها) از توزیع بواسون با پارامتر λt سروی کنند

که راه دلگی برای ماقنن مرآینه بواسون است
 $s_n \sim \text{Erlang}$
 $s_n \sim \text{uniform}$ با $n-1$ درجه آزادی
 مرآینه بواسون \sim sum of n independent exponential distributions

constructive

تعريف 1 مرآینه بواسون

in! $\text{Exp}(\lambda)$ the inter arrival period \sim iid renewal

implicit


تعريف 2 مرآینه بواسون

مرآینه بواسون با λ independent increment, stationary increment
 و تعداد های داشته در هر بازه t از توزیع بواسون با پارامتر λt سروی کنند

تعريف 3 مرآینه بواسون

limit of a shrinking Bernoulli process

Def. 3 \rightarrow Def 1



$$p = \lambda \Delta \quad (\Delta < \frac{1}{\lambda})$$

$$M(m) \sim \text{Geo}(\lambda \Delta)$$

$$X(t) = \Delta \times M(m)$$

: نتیج دهن Exp & Geo نتیج ایات کم می باشد

$$M(m) \sim (\lambda \Delta) (1 - \lambda \Delta)^{m-1}$$

$$P(t < X_i < t + \Delta) = (\lambda \Delta) (1 - \lambda \Delta)^{\frac{t}{\Delta} - 1}$$

$$\lim_{\Delta \rightarrow 0} \frac{P(t < X_i < t + \Delta)}{\Delta} = \lim_{\Delta \rightarrow 0} \lambda (1 - \lambda \Delta)^{\frac{t}{\Delta} - 1}$$

$$f_{X_i}(t) = \lambda e^{-\lambda t} u(t)$$

$$f_{X_i}(t) = \lambda e^{-\lambda t} u(t)$$


Def 3 \rightarrow Def 2

رسانیده فرایند برآوری خواهد داشت \oplus

$$\text{Binom}\left(\lfloor \frac{t}{\Delta} \rfloor, \lambda \Delta\right) \approx \text{پسون}(\lambda t), \text{Bern}(\lambda \Delta) \text{ بر } \left\lfloor \frac{t}{\Delta} \right\rfloor \text{ اگر}$$


$$\lim_{\Delta \rightarrow 0} \text{Binom}\left(\lfloor \frac{t}{\Delta} \rfloor, \lambda \Delta\right) = \text{poisson}(\lambda t)$$

poisson process Merging



اگر فرایند های P_1, P_2 پواسن P_1, P_2 باشند،
فرایند $P_1 \oplus P_2$ یک فرایند پواسن بازخ $\lambda_1 + \lambda_2$ خواهد بود

Def 2 ایات



$$\begin{aligned} \oplus \quad P(N_1(t) + N_2(t) = k) &= \sum_{i=0}^k \frac{(\lambda_1 t)^i}{i!} e^{-\lambda_1 t} \frac{(\lambda_2 t)^{k-i}}{(k-i)!} e^{-\lambda_2 t} \\ &= e^{-(\lambda_1 + \lambda_2)t} \sum_{i=0}^k \frac{\lambda_1^i \lambda_2^{k-i}}{i! (k-i)!} \frac{k!}{(k)_i \lambda_1^i \lambda_2^{k-i}} \end{aligned}$$

$$= \frac{((\lambda_1 + \lambda_2)t)^k}{k!} e^{-(\lambda_1 + \lambda_2)t} \xrightarrow{\text{poisson}} \text{poisson}$$

- $\oplus \quad N_1 \perp\!\!\!\perp N'_1 \quad \text{I}$
- $\oplus \quad N_2 \perp\!\!\!\perp N'_2 \quad \text{II}$
- $P_1 \perp\!\!\!\perp P_2 \rightarrow N_1 \perp\!\!\!\perp N_2, N'_1 \perp\!\!\!\perp N'_2 \quad \text{III}$

$$\text{I} \text{ II} \rightarrow N_1 + N_2 \perp\!\!\!\perp N'_1 + N'_2 \xrightarrow{\text{independent}} \text{independent}$$

poisson process merging

Def 3 ! باید باشد


$$\begin{aligned} P_1 &\xrightarrow{\Delta} \lambda_1 \Delta = p_1 \\ \Downarrow \\ P_2 &\xrightarrow{\Delta} \lambda_2 \Delta = p_2 \\ &\xrightarrow{\Delta} p_3 \end{aligned}$$

P_1, P_2 رو ب صورت مجزا های برندگی با پارامتر λ_1, λ_2 در نظر می گیریم.
 $P_1 \oplus P_2$ رو ب صورت اجتماع برندگی های عدد bin در نظر می گیریم و
اگر جفت P_1, P_2 رخ داده باشد، آنرا در خروجی لحاظ می کنیم.

$$P_3 = P_1 + P_2 - P_1 P_2 = (\lambda_1 + \lambda_2) \Delta + \lambda_1 \lambda_2 \Delta^2 \xrightarrow{\Delta \rightarrow 0} \text{Bern}((\lambda_1 + \lambda_2) \Delta) \checkmark$$

همین واضح است که برابر با پواسون با پارامتر $(\lambda_1 + \lambda_2) \Delta$ و $\lfloor \frac{t}{\Delta} \rfloor \rightarrow \infty$, $(\lambda_1 + \lambda_2) \Delta + O(\Delta^2) \rightarrow 0$

⊕ احتمال رخ دادن هم زمان $P_1, P_2 \neq 0$ و $P_1 P_2 \neq 0$ و واضح است که برندگی های عدد bin از هم جدا شده اند



$$X_i'' = \min \{ X_i, X_i' \}, \quad X_i \perp\!\!\!\perp X_i', \quad X_i \sim \lambda_i e^{-\lambda_i n}$$

$$X_i' \sim \lambda_i e^{-\lambda_i n}$$

$$\mathbb{P}(X_i'' > n) \stackrel{\text{def}}{=} \mathbb{P}(X_i > n) \mathbb{P}(X_i' > n) = e^{-(\lambda_1 + \lambda_2)n}$$

$$\rightarrow X_i'' \sim \text{Exp}(\lambda_1 + \lambda_2)$$

همین برای X_2'' نیز واضح است که طور مساوی برابر \min دو عایق مینیم با پارامتر $\lambda_1, \lambda_2, \lambda_1 + \lambda_2$ است زیرا فرآیند P_1 از X_1 بعد از آن تعریف شده است و X_1 یک عایق با پارامتر λ_1 است که خودش P_2 نیز به دلیل memoryless بودن از X_1 تا X_2 یک عایق با پارامتر λ_2 است


$$X_2'' = \min \{ X_2, X_1' | n > X_1 \} \sim \text{Exp}(\lambda_1 + \lambda_2)$$

با مین صورت تمام X_i'' ها $\text{Exp}(\lambda_1 + \lambda_2)$ خواهند بود to inter arrival period

poisson process splitting

AKA branching
AKA Forking

مثلاً اگر انتخاب یکی در میان ۴ تاً و s_1, s_2, s_3, s_4 باشد و از فرایند اول رو داشته باشیم، می‌توانیم s_2 فرایند دوم بین این ۲ تاً بین خواهد داد.



اگر split موند به صورت determinstic باشد، نتیجه حتماً می‌شود.

هر ساخته فرایند پواسون می‌شود

برای X_i' و X_i'' ها جمع Exp دارد (نحوه Erlang دو تراوید بود)

اگر split موند به صورت random با احتمال p هر چیز بروی ساخته اول داشته باشد p -ا بروی ساخته دوم، ادن وقت هم ساخته‌ها مستقل می‌شون.
($\lambda(1-p)$ ساخته اول، پواسون با پارامتر λp و ساخته دوم، پواسون با پارامتر λ)

$$\left. \begin{array}{l} X'_i = \sum_{i=1}^k X_i \\ X_i \stackrel{iid}{\sim} \text{Exp} \\ k \sim \text{Geo} \end{array} \right\} \rightarrow X'_i \sim \text{Exp}$$

برای X'_i مجموع k تاً Exp باشد که k تاً می‌باشد \rightarrow Def 1 ایجاب می‌شود

$$\left. \begin{array}{l} \text{برای } k \text{ تاً Binomial \& } m+k \text{ تاً Bernoulli} \\ \text{برای } k \text{ تاً Binomial \& } m \text{ تاً Bernoulli} \end{array} \right\} \rightarrow \text{Def 2 ایجاب می‌شود}$$

$$! \quad \left. \begin{array}{l} \text{برای } p(N_1(t)=m, N_2(t)=k) = p(N_1(t)=m) p(N_2(t)=k) \\ \text{که ایجاب می‌شود} \end{array} \right\} \rightarrow \text{Def 3 ایجاب می‌شود}$$

$$\begin{aligned} p(N_1=m, N_2=k) &= \frac{p(N_1=m, N_2=k | N_{\text{mother}}=m+k)}{\frac{(m+k)!}{m! k!} p^m (1-p)^k} \frac{p(N_{\text{mother}}=m+k)}{\frac{(m+k)^{m+k}}{(m+k)!} e^{-\lambda t} \frac{-\lambda t}{e^{-\lambda pt} - \lambda(1-p)t}} \\ &= \frac{(\lambda pt)^m}{m!} e^{-\lambda pt} \times \frac{(\lambda(1-p)t)^k}{k!} e^{-\lambda(1-p)t} \\ &\quad \left. \begin{array}{l} p(N_1(t)=m) \\ \text{poisson}(\lambda pt) \end{array} \right. \quad \left. \begin{array}{l} p(N_2(t)=k) \\ \text{poisson}(\lambda(1-p)t) \end{array} \right. \end{aligned}$$

Importance of poisson process

renewal




if P_1, \dots, P_n are independent arrival processes, not necessarily from the same distribution,

then $\lim_{n \rightarrow \infty} P_1 + \dots + P_n$ is a poisson process

$$\text{rate}_i \rightarrow 0 \quad (n \times \text{rate}_i = \lambda)$$

CLT

Proof



$$S_i = \min \{ X_i^{(1)}, \dots, X_i^{(n)} \}$$

$$\Rightarrow F_{S_i}(s_i) = 1 - \prod_{j=1}^n (1 - F_j(s_i))$$


$$\frac{d}{ds_i} F_{S_i}(s_i) = \sum_{i=1}^n F_i(s_i) \prod_{\substack{j=1 \\ j \neq i}}^n (1 - F_j(s_i))$$

این دستی نیست
و محدودیت ندارد
با این

حرت تابعی دلی چون s_i کوچک هست با سری سلور F_{S_i} و ترتیب میزیم

$$\begin{aligned} F_{S_i}(s_i) &\approx \sum_{i=1}^n F_i(0) \prod_{\substack{j=1 \\ j \neq i}}^n \left(1 - \frac{F_j(0)s_i}{e^{-F_j(0)s_i}} \right) = \sum_{i=1}^n F_i(0) e^{-s_i \sum_{\substack{j=1 \\ j \neq i}}^n F_j(0)} \\ &= e^{-s_i \sum_{j=1}^n F_j(0)} \underbrace{\sum_{i=1}^n F_i(0) \frac{e^{\sum_{j=1}^n F_j(0)s_i}}{1}}_{\lambda \triangleq \sum_{i=1}^n F_i(0)} \stackrel{\lambda \triangleq \sum_{i=1}^n F_i(0)}{=} \lambda e^{-\lambda s_i} u(s_i) \end{aligned}$$

Non-homogeneous poisson process



جیزی که این دریم پواسون همان بود

بله حقیقت Def 3 میگیرد احتمال هر سیر اولین Δ میگیرد. این میگیرد

چون λ نسبتی است X_i مام عایی نیست و باید این memoryless هست

همین خاست stationary increment و هم زاده

شکرها در هر مجموعه borel set از توزیع پواسون میاد و خاست independent increment

$$P(N(t)=k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

$$\lambda = \int_0^t \lambda(t') dt'$$

P_{X_i} extra

$X_i \sim \text{Geo}$ with variable p_i

$$P_m \prod_{i=1}^{m-1} (1-p_i)$$

$$P_{X_i}(t) = \lambda(t)\Delta \prod_{i=1}^{t/\Delta} (1 - \lambda(i\Delta)\Delta)$$


$$= \lambda(t)\Delta e^{-\sum_{i=1}^{t/\Delta} \lambda(i\Delta)\Delta} \stackrel{\text{def}}{=} \lambda(t)e^{-\int_0^t \lambda(t')dt'}$$

Gaussian process

\neq arrival process

Session 10

1404.1.16



$$\{X(t, \omega) \mid t \geq 0\}$$

⊗ بہ اڑی مہربنگ زبانی ملے ہیک
ستھر تھادنی کا وہی دارم

* فرایند های پردازنده با سرعت کمتر از ۱۰۰۰ MHz rate با سرعت کمتر از ۱۰۰۰ MHz kernel نهاده می شوند.

NTK, regression, control theory, LTI (lo \leftarrow $\sigma_1 b^T \otimes$)

Review

MGF

$$M_X(r) = \mathbb{E}[e^{rX}] = \int_{-\infty}^{\infty} e^{rx} f_X(x) dx \equiv \begin{bmatrix} e^{rx_j} \\ r x_j \end{bmatrix} @ \begin{bmatrix} f_X(x) \\ x \end{bmatrix}$$

$$\text{inverse: } f_X(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} M_X(r) e^{-rx} dr$$

$$X \sim N(\mu, \sigma^2) \rightarrow M_X(r) = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{-(x-\mu)^2}{2\sigma^2}} e^{rx} dx$$

$$= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{-(x-\mu-r\sigma^2)^2}{2\sigma^2}} e^{\frac{r^2\sigma^4 + 2r\mu\sigma^2}{2\sigma^2}} dx$$

$$= e^{r\mu + \frac{1}{2}r^2\sigma^2}$$


Review

Jointly Gaussian

$$X, Y \sim \text{J.G}(\mu_n, \mu_y, \epsilon_n, \epsilon_y, \rho)$$

$$f_{XY}(x,y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \frac{1}{\sigma_x \sigma_y} \exp \left[\frac{-1}{2(1-\rho^2)} \left(\frac{(x-\mu_x)^2}{\sigma_x^2} + \frac{(y-\mu_y)^2}{\sigma_y^2} - 2\rho \frac{(x-\mu_x)(y-\mu_y)}{\sigma_x \sigma_y} \right) \right]$$


$$-1 \leq \varphi \leq 1$$




$$P_{J.G} \approx \frac{C}{\sqrt{1-p^2}} e^{-\frac{(n-j)^2}{2(1-p^2)}} \quad \text{اگر } p \rightarrow 1 \text{ دون وقت}$$

≈ 0 باشد $n = j$

⊗ مفهیم میانگین مقدار ارتباط میان X و Y باشد و از استدلال خلی صنعتی تر و دلیل با توجه به اینکه ج.ج. میانگین مقدار $\sum M$ با $J.G.$ باشد داشته باشیم $\Leftrightarrow \rho = 0$: مین ارتباط میان X و Y باشد $J.G.$ دائم :



$$\forall k, l \in \mathbb{N} \quad \mathbb{E}[(X - \mu_X)^k (Y - \mu_Y)^l] = \mathbb{E}[(X - \mu_X)^k] \mathbb{E}[(Y - \mu_Y)^l] \quad \text{⊗ برای برقراری استدلال باید داشت باشیم:}$$



یک مدل نسبی کوادسی باشد اما $J.G.$ نباشد:
 $Y = X$ و همچنان $X \sim N(0, \sigma^2)$. آن سیر آندر X در غیر این صورت $Y = -X$.

$$f_{Y|X}(y|x) = \frac{1}{2} \delta(y-x) + \frac{1}{2} \delta(y+x)$$

$$\text{cov}(X, Y) = \mathbb{E}[XY] = \frac{1}{2} \mathbb{E}[XX] + \frac{1}{2} \mathbb{E}[X(-X)]$$

$$\rho = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \text{var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = 0$$

: نسبتی کوادسی سواره زد $-1 \leq \rho \leq 1$

با این دلیل میتوانیم $J.G$ را بودن $\rho = 0$ دلیل کنیم.

$$\langle u, v \rangle^2 \leq \langle u, u \rangle \cdot \langle v, v \rangle$$

$$\downarrow$$

$$\text{cov}(X, Y)^2 \leq \text{cov}(X, X) \cdot \text{cov}(Y, Y)$$

Covariance matrix

$$\Sigma = \begin{bmatrix} \text{Var}(x) & \text{cov}(x,y) \\ \text{cov}(x,y) & \text{Var}(y) \end{bmatrix} = \begin{bmatrix} \sigma_x^2 & \rho \sigma_x \sigma_y \\ \rho \sigma_x \sigma_y & \sigma_y^2 \end{bmatrix} \in \mathbb{R}^2$$

$$\det(\Sigma) = \sigma_x^2 \sigma_y^2 (1 - \rho^2)$$

$$\Sigma^{-1} = \frac{1}{1 - \rho^2} \begin{bmatrix} \frac{1}{\sigma_x^2} & \frac{-\rho}{\sigma_x \sigma_y} \\ \frac{-\rho}{\sigma_x \sigma_y} & \frac{1}{\sigma_y^2} \end{bmatrix}$$

$\det(\Sigma) \neq 0$ اگر $-1 < \rho < 1$ و فرم ماتریس Σ دارای دو ریشه متمم باز با رفع اجسام درست می‌شود

$\xrightarrow[\text{zero mean case 2}]{\text{J.G. فرم ماتریس}} f_{\underline{x}}(n) = f_{x,y}(n, y) = \frac{1}{2\pi \sqrt{\det(\Sigma)}} \exp\left(-\frac{1}{2} \underline{x}^T \Sigma^{-1} \underline{x}\right)$

$$\underline{x} = \begin{bmatrix} x \\ y \end{bmatrix}$$

بردارهای J.G. معادل برداری است که اینها هستند به صورت مستقل کاری باشند و بعد روی این بردار بدل خواهی اعمال شوند:

$$\underline{u} = \begin{bmatrix} u_1 \sim N(0,1) \\ u_2 \sim N(0,1) \end{bmatrix} \quad u_1 \perp\!\!\!\perp u_2, \quad \Sigma^{\frac{1}{2}} \Sigma^{\frac{1}{2}} = \Sigma$$

$$f_{\underline{u}}(\underline{u}) = f_{u_1}(u_1) \times f_{u_2}(u_2) = \frac{1}{2\pi} e^{-\frac{u_1^2 + u_2^2}{2}} = \frac{1}{2\pi} e^{-\frac{\|\underline{u}\|_2^2}{2}}$$

بردارهای Σ پس از تجزیه $\Sigma^{\frac{1}{2}}$ بردار \underline{u} را با $\Sigma^{\frac{1}{2}}$ عکس Σ را با $\Sigma^{\frac{1}{2}}$ عکس Σ می‌شوند.
 $\text{Var}(\text{vector}) \equiv \det(\text{cov matrix})$.

$$\underline{x} \triangleq \Sigma^{\frac{1}{2}} \underline{u} + \underline{\mu}$$

change of variable $\xrightarrow{} f_{\underline{x}}(n) = \frac{1}{|\det(\Sigma^{\frac{1}{2}})|} f_{\underline{u}}(\Sigma^{\frac{1}{2}}(n - \underline{\mu})) = \frac{1}{\sqrt{\det(\Sigma)}} \frac{1}{2\pi} e^{-\frac{1}{2} (n - \underline{\mu})^T \Sigma^{-1} (n - \underline{\mu})}$

Σ is always PSD

(proof) $\forall \alpha \in \mathbb{R}^n \quad \alpha^T \Sigma \alpha = \sum_{i,j=1}^n \alpha_i \alpha_j \Sigma_{ij} = \mathbb{E} \left[\sum_{i,j=1}^n \alpha_i \alpha_j (x_i - \mu_i)(x_j - \mu_j) \right] = \mathbb{E} \left[\left(\sum_{i=1}^n \alpha_i (x_i - \mu_i) \right)^2 \right] \geq 0$

Σ PSD از از ترتیب متوالی R.V. \underline{x} deterministically می‌باشد (متوجه جبر نظری)

$$\sum_{i=1}^n \alpha_i (x_i - \mu_i) \neq 0$$

$$\Sigma^{\frac{1}{2}} = \Lambda^{\frac{1}{2}} Q^T$$

positive definite matrix \longrightarrow full rank matrix

symmetric matrix \longrightarrow eig val decomp $\Sigma = Q \Lambda Q^T$

Jointly Gaussian

AKA multivariate Gaussian

$$x = [x_1 \dots x_n] \in \mathbb{R}^n$$

$$f_{\underline{x}}(\underline{n}) = \frac{1}{\sqrt{(2\pi)^n |\det(\Sigma)|}} \exp\left(-\frac{1}{2} (\underline{n} - \underline{\mu})^T \Sigma^{-1} (\underline{n} - \underline{\mu})\right) \quad \forall \underline{n} \in \mathbb{R}^n$$

$\underline{\mu} \in \mathbb{R}^n \longrightarrow$ mean vector

$\Sigma \in \mathbb{R}^{n \times n}$ (≥ 0) \rightarrow covariance matrix

کل از X که $X \sim f(x)$ دارد M_x می‌باشد و M_x را marginalize کنید تا $f(x)$ را بگیرید.

X_1, \dots, X_n are independent $\xleftrightarrow{\text{J.G.}}$ Σ is diagonal \circledast

$$\underline{X_1} \perp\!\!\!\perp \underline{X_2} \xleftarrow{\text{J.G}} \sum = \begin{bmatrix} \text{■} & \text{○} \\ \text{○} & \text{■} \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \quad \otimes$$

⊗ می توان x_1, \dots, x_m را با $\underline{x} \sim N(\underline{\mu}, \Sigma) \in \mathbb{R}^n$ ساخت که مجموع \sum دارای Full rank باشد.

$$\Sigma = \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx}^T & \Sigma_{yy} \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} \rightarrow x|y \sim N\left(\Sigma_{xy}\Sigma_{yy}^{-1}(y - \mu_y) + \mu_x, \Sigma_{xx}\right)$$

اگر \oplus کو \oplus کرنے والا \mathbb{F} کا ایک مولٹیپلیکیٹر A ہے تو $\mathbf{x} = [x_1 \dots x_n] \sim \mathbb{F} \cdot G$

$$A \underline{x} \sim J.G \quad \text{per change of variable}$$

Gaussian process

$\{X(t) \mid t \in T\}$ is a Gp iff $\forall n \in N, \forall t_1, \dots, t_n \in T \quad [X(t_1) \dots X(t_n)] \sim J.G$

brace: {
 discrete T → DT-GP ($Z, Z_{>0}, \dots$)
 continuous T → CT-GP ($\mathbb{R}, \mathbb{R}_{>0}, \dots$)

این تعریف constructive نسبت. میگذارد
که جزوی فرازندی به دست آورده که این خاصیت
دو داشت، فرازنت GP ع

$$IID\; Gp \subset DT-Gp$$

$$w = \{ w(n) \mid n \in \mathbb{Z} \} \quad \dots, w(-1), w(0), w(1), \dots \xrightarrow{\text{ind}} N(\omega, \epsilon^2)$$

$$\mu_w(n) = \emptyset$$

$$\sum_{ww} (n, n+k) = \epsilon^2 \delta_{n, n+k} = \epsilon^2 \delta(k=0)$$

Cima stationary

$M(t): T \rightarrow \mathbb{R}$ فریزه کویی میکند $M \in \mathbb{R}^n$ و $\sum_{i=1}^n M_i < \infty$ و $M(t)$ جا. جا. میکند \otimes
 $\Sigma(t_1, t_2): T \times T \rightarrow \mathbb{R}$ فریزه کویی میکند $\Sigma \in \mathbb{R}^{n \times n}$,
 فریزه کویی میکند $\Sigma(t_1, t_2)$, $M(t)$ بفریزه کویی میکند. فریزه کویی λ بفریزه کویی میکند $\lambda M(t)$ \otimes

$\oplus M(n), \Sigma(n, m)$ belong to a Gp iff $\forall n \in \mathbb{N}, \forall t_1, \dots, t_n \in T \quad [\Sigma(t_i, t_j)]_{i,j=1}^n$
 is symmetric and psd (no conditions for $M(n)$)

$$\left\{ \begin{array}{l} \text{e.g. } M(n) = \emptyset, \Sigma(n, m) = \delta_{n,m} \quad \text{valid} \\ \text{e.g. } M(n) = \sin(2\pi \omega n), \Sigma(n, m) = \rho e^{-|n-m|} \quad \text{valid} \end{array} \right.$$

AKA Gaussian Random Walk

Gaussian sum process $\subseteq DT\text{-Gp}$

$$S = \{s(n) \mid n \in \mathbb{N}\}$$

$$s(n) = \sum_{i=1}^n w(i) \quad , \quad w(i) \text{ is IID Gp}$$

$$\mu_s(n) = \mathbb{E} \left[\sum_{i=1}^n w(i) \right] = 0$$

$$\Sigma_{ss}(n, m) = \mathbb{E} [s(n) s(m)] \xrightarrow{n \leq m} \mathbb{E} [s(n) (s(n) + w(n+1) + \dots + w(m))]$$

$$= \underbrace{\mathbb{E} [s(n)^2]}_{n \in \mathbb{Z}^2} + \underbrace{\mathbb{E} [(w(1) + \dots + w(n))(w(n+1) + \dots + w(m))]}_{w(i)s \text{ are iid}} \rightarrow 0$$

$$\rightarrow \Sigma_s(n, m) = \min(n, m) \sigma^2 \quad \text{valid}$$

$$\forall n \text{ دلخواه کویی است. باید } \Sigma \text{ جا. جا. میکند.} \quad \Sigma = \begin{bmatrix} s(1) \\ s(2) \\ \vdots \\ s(n) \end{bmatrix} = \begin{bmatrix} 1 & \Delta & & \\ 1 & 1 & \dots & 1 \\ \vdots & & & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \begin{bmatrix} w(1) \\ w(2) \\ \vdots \\ w(n) \end{bmatrix}$$

↓
change of variable

stationary
 $\sum_{i=1}^{n+m} w(i) \rightarrow \sum_{i=1}^n w(i)$ باید
 مم توزیع نشوند

Gauss-Markov process

$\subset DT-GP$

$$X = \{X(n) \mid n \in \mathbb{Z}_{\geq 0}\}$$

$$X(0) = \emptyset$$

$$X(n+1) = \alpha X(n) + w(n)$$

$$|\alpha| < 1 \rightarrow w(n) \text{ is IID GP}$$

$$\rightarrow X(n) = w(n-1) + \alpha w(n-2) + \dots + \alpha^{n-1} w(0)$$

$$\rightarrow M_X(n) = 0$$

$$\begin{aligned} \cdots \sum_{xx}(n, n+k) &= E[X(n)X(n+k)] \\ &= \sigma^2 \frac{1-\alpha^{2n}}{1-\alpha^2} \alpha^k \end{aligned}$$

$k \rightarrow \infty$ جهتی

اگر $n \approx \sum_{xx} \approx |\alpha| < 1$ جون بزرگ باشد n ای داریم
که $X(n)$ ای داریم که $w(n)$ ای داریم
که $X(n)$ ای داریم که $w(n)$ ای داریم

لطفاً

$$X = \{X(n) \mid n \in \mathbb{Z}\}$$

$$X(n+1) = \alpha X(n) + w(n)$$

$|\alpha| < 1$, $w(n)$ is IID GP

لطفاً

$$\rightarrow X(n) =$$

$$\rightarrow M_X(n) = 0$$

$$\cdots \sum_{xx}(n, n+k) = \frac{\sigma^2}{1-\alpha^2} \alpha^k$$

ای داریم stationary

ای داریم ای داریم که $X(n)$ ای داریم stationary


$$\forall t, u \in T \quad E[X(t)] = E[X(0)]$$

$$\text{and } \sum_{xx}(t, t+u) = \sum_{xx}(0, u)$$

ای داریم ای داریم

ای داریم ای داریم

ای داریم ای داریم ای داریم stationary



stationarity AKA strictly stationary

$$\forall n \in \mathbb{N} \quad \forall t_1, \dots, t_n \in T \quad \forall \Delta \mid t_i + \Delta \in T$$

X is stationary if

$$(X(t_1) \dots X(t_n)) \stackrel{\text{I.D.}}{=} (X(t_1 + \Delta) \dots X(t_n + \Delta))$$

\equiv

$$F_{X(t_1) \dots X(t_n)}(n, \dots, n_n) = F_{X(t_1 + \Delta) \dots X(t_n + \Delta)}(n, \dots, n_n)$$

اسی ای برای محدود تحریت نهادنی \otimes
متغیر تصادنی

جذبیت نهادنی هم توزیع باشند \otimes $X(t_1)$

Wide sense stationary (WSS) AKA weakly stationary

AKA second-order stationary


2 و 1 درجه مونت \Rightarrow WSS \otimes
نهادنی

X is WSS if $\forall t, u \in T$

- $E[X(t)] = E[X(u)] = \text{const}$

چون فقط \Rightarrow خاصیت داره
پس میتوانیم Σ_x را محاسبه کنیم

- $\Sigma_{xx}(t, t+u) = \Sigma_{xx}(0, u) \triangleq \Sigma_x(u)$



$\Delta t = 0 \Rightarrow \sigma_{\max}, \sigma_{\min} \Sigma_x$ باز رفع \otimes
آنچه انداده باشیم \Rightarrow (Lo Var). جاها σ^2 داشته باشیم \Rightarrow خواهد بود.
درباره بعد σ_{\max} تا σ_{\min} .

stationary $\xrightarrow{\text{GP}}$ WSS \otimes

stationary \longrightarrow WSS \otimes

Ergodicity

• n ergodic \Rightarrow $x(t_0, \omega)$ جزوی ای از $x(t, \omega)$ که Σ_x کی statistical properties \Rightarrow sample path Σ_x باشند \Rightarrow $E[X(t_0)]$ \Rightarrow توزیع

if $\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{i=1}^N X(t_0, \omega_i) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{t_0 - \frac{T}{2}}^{t_0 + \frac{T}{2}} X(t, \omega) dt$ then $X(t, \omega)$ is min-ergodic

$\underbrace{\quad}_{\text{ensemble average}}$ $\underbrace{\quad}_{\text{time average}}$

\equiv ground truth

آخر علاوه بر عمان اول، همه مانند این توزیع را داشته باشند، فرایند ergodic خواهد بود.

AKA orthonormal expansion

$$DT-GP \longrightarrow CT-GP$$

$$\{\phi_i(t) \mid i \in N\} \quad \phi_i: \mathbb{R} \rightarrow \mathbb{C}$$

orthonormal پایه های
با مقدار روابع

$$\int_{-\infty}^{\infty} |\phi_i(t)|^2 dt = 1 \quad \forall i \in N \quad \text{سرم برش بودن}$$

$$\int_{-\infty}^{\infty} \phi_i(t) \phi_j^H(t) dt = 0 \quad i \neq j \quad \text{سرم تام} \quad \left(\equiv \int_{-\infty}^{\infty} \phi_i(t) \phi_j(t) dt = \delta_{ij} \right)$$

$$\rightarrow X(t) = \sum_{i=1}^{\infty} x_i \phi_i(t)$$

$$x_i = \int_{-\infty}^{\infty} X(t) \phi_i^H(t) dt$$

ساختن فریزهای CT درست است اما درین
باکس پایه های orthonormal از روی فریزهای DT
فریزهای CT ساخت.
بسته به نرخ پایه اختیار می شود، طبق مای مختلف
از فریزهای CT را درین ساخت.

⊗ در ادامه تعاریف برای زیر مجموعه های مختلف constructive
و destructive می شود

Taylor series Basis

$$\phi_n(t) = \frac{t^n}{n!} \longrightarrow \left\{ X(t) \mid X(t) = \sum_{i=0}^{\infty} \frac{w(i)}{i!} t^i \right\}$$

IID GP

pulse Basis


$$\phi_n(t) = \begin{cases} 1 & n \leq t < n+1 \\ 0 & \text{باقی} \end{cases}$$

فراسایی که درست این پایه ساخته شود
زیرا آن غیر صحیح سیستم بجزرد معلوم نیست.

⊗ آن فقط صحیح سیستم بجزرد معلوم نیست

$$\begin{aligned} E[X(t) X(t+\Delta)] &= E \left[\sum_{i=0}^{\infty} x_i \phi_i(t) \cdot \sum_{j=0}^{\infty} x_j \phi_j(t+\Delta) \right] \\ &= E \left[\sum_{i,j=0}^{\infty} x_i x_j \phi_i(t) \phi_j(t+\Delta) \right] \\ &= \sum_{i,j=0}^{\infty} \phi_i(t) \phi_j(t+\Delta) E[x_i x_j] \end{aligned}$$

$$\begin{aligned}
 & \sum_{xx} (t_1, t_2) = E \left[x(t_1) x(t_2) \right] \\
 &= E \left[\sum_{n,k=-\infty}^{\infty} x\left(\frac{n}{2B}\right) x\left(\frac{k}{2B}\right) \text{sinc}(2Bt_1-n) \text{sinc}(2Bt_2-k) \right] \\
 &\stackrel{!}{=} E \left[\sum_{n=-\infty}^{\infty} x^2\left(\frac{n}{2B}\right) \text{sinc}(2Bt_1-n) \text{sinc}(2Bt_2-n) \right] \\
 &= e^2 \sum_{n=-\infty}^{\infty} \text{sinc}(2Bt_1-n) \text{sinc}(2Bt_2-n) \\
 &= e^2 \text{sinc}\left(2B\overbrace{(t_2-t_1)}^{\Delta t}\right)
 \end{aligned}$$



۴) تواجع innovation میتواند band limited نباید داشته باشند

۵) اینجا نیاز دارد نسبت $\frac{\text{میانه}}{\text{میانه}} = 1$ داشته باشیم و مونت خود پایه ها و قدر زیاد بشه (\gg بکار میگیرد) به صفر میل میگردد

سرمه $\text{Var}(X(t))$ را از فناوری کنید

مساوده می کند و اینکه دارد و اینکه cov. Func. $\sum_{xx}(t,t) = \sigma^2$ فرازی \leftarrow const \rightarrow GyP و جون ایت \curvearrowright GyP \curvearrowright GyP stationary

- ⊗ میور دست Gaussian sinc process نسبت ب پاریس سری ذریعہ کمرو
- ⊗ مان طور کہ مسالہ میں کوڈ ۱۰ $\rightarrow \infty$ \rightarrow At \rightarrow ۰ ہے سمت استکل میں رویم و وہی دیستگی بیشتر میں رویم

$$\textcircled{4} \quad \text{CFS basis} = \phi_n(t) = \begin{cases} \frac{1}{\sqrt{T}} e^{\frac{j2\pi nt}{T}} & |t| \leq \frac{T}{2} \\ 0 & \text{otherwise} \end{cases} \quad \text{exponential form}$$

$$= \begin{cases} \sqrt{\frac{2}{T}} \cos\left(\frac{2\pi nt}{T}\right) & n > 0, |t| \leq \frac{T}{2} \\ \sqrt{\frac{1}{T}} & n = 0, |t| \leq \frac{T}{2} \\ \sqrt{\frac{2}{T}} \sin\left(\frac{-2\pi nt}{T}\right) & n < 0, |t| \leq \frac{T}{2} \\ 0 & \text{otherwise} \end{cases} \quad \text{sine - cosine form}$$




$$\textcircled{*} \quad x_n \in \mathbb{R} \iff x(t) \text{ is even}$$

stationary \Leftrightarrow $E[x(t)]$ $\text{فوري} \Rightarrow$ $E[x(t)^2]$ ثابت

$\sum_{xx}(t, t+T) = E[x(t)^2]$ \Leftrightarrow periodic \Rightarrow $E[x(t)]$ ثابت


Filtered CT processes

session 15
1404.2.1



يعني اگر مجموع از این دو ورودی (t) و $(t-\tau)$ که صفر هست \Rightarrow دستورات \Rightarrow LTI با پاسخ میان سهند \Rightarrow صورت \Rightarrow $x[t] = \sum_{n=-\infty}^{\infty} x[n] \delta[t-n]$ \Rightarrow صورت \Rightarrow جون در ورودی t و میان \Rightarrow صورت

$$\circledast Y(t) = x(t) * h(t) = \int_{-\infty}^{\infty} x(t-\tau) h(\tau) d\tau$$



$$\begin{aligned} M_Y(t) &= \mathbb{E} \left[\int_{-\infty}^{\infty} x(t-\tau) h(\tau) d\tau \right] \\ &= \int_{-\infty}^{\infty} \mathbb{E}[x(t-\tau)] h(\tau) d\tau = M_x(t) * h(t) \end{aligned}$$

$$\begin{aligned} \text{zero mean } Y &\Rightarrow \\ \sum_{yy}(t, t+\tau) &= \mathbb{E} \left[\int_{-\infty}^{\infty} x(t-u) h(u) du \cdot \int_{-\infty}^{\infty} x(t+\tau-u) h(v) dv \right] \\ &= \iint_{-\infty}^{\infty} \mathbb{E}[x(t-u)x(t+\tau-v)] h(u) h(v) du dv \\ &\stackrel{\text{if WSS}}{=} \sum_{xx}(t, t+\tau) \end{aligned}$$

$$\equiv h(-\tau) * \sum_x(\tau) * h(\tau)$$

دستورات


power spectral density \rightsquigarrow defined for WSS sp

$$S_x(f) = \text{FT} \left\{ \sum_x(\tau) \right\} = \int_{-\infty}^{\infty} \sum_x(\tau) e^{-j2\pi f \tau} d\tau$$

$$\sum_x(0) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_x(f) e^{j2\pi f \tau} df$$

$$\rightarrow \sum_x(0) = \mathbb{E} [|x(t)|^2] = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_x(f) df$$

for WSS power ($x(t)$)



$$\text{Energy } (x(t)) = \mathbb{E} \left[\int_0^T |x(t)|^2 dt \right]$$

$$\text{power } (x(t)) = \lim_{T \rightarrow \infty} \frac{1}{T} \text{Energy } (x(t))$$

For WSS $x(t)$

$$\text{power } (x(t)) = \mathbb{E} [|x(t)|^2]$$


$\mathbb{E}[|x(t)|^2]$ is const

$$M_x(t), \sum_x(\omega) \xrightarrow{h} M_x(t) * h(t), \quad h(-\omega) * (\sum_x(\omega))$$

$$\bar{M}_x(f), S_x(f) \xrightarrow{H} \bar{M}_x(f) H(f), \quad S_x(f) |H(f)|^2$$


$$2\pi \sum_y(0) = \int_{-\infty}^{\infty} S_y(f) df = \int_{-\infty}^{\infty} S_x(f) |H(f)|^2 df$$

$$= \int_{\pm f_0 - \varepsilon}^{\pm f_0 + \varepsilon} S_x(f) df \simeq 2\varepsilon (S_x(f_0) + S_x(-f_0))$$



در توان یک مجموعه از صفات که زیر توسط آن توان \sum_x را دارد.
 ۱) zero mean GP $S_x(f)$! \otimes
 ۲) $H(f)$ دارم و $|H(f)|^2$ دارم و $S_y(f) = S_x(f) |H(f)|^2$ احیت است.
 ۳) با توجه به اینکه $S_x(f)$ دارد $S_y(f)$ نیز دارد \otimes


white Noise



$$\frac{1}{2\pi} \int_{-\infty}^{\infty} S_x(f) df = 1$$

۱) noise مربوط به spectral density \otimes
 ۲) مساحت زیر آن ثابت می‌ماند

۳) در حالت حدی اثر $S_x(f)$ را نسبت نزدیک نویز خاصی نمایم
 ۴) دست بیشتر که در عمل وجود ندارد اما ویرانی های جالبی دارد



۱) دارد
 ۲) دارد

$$\text{if } X(t) \text{ is white noise} \rightarrow \frac{1}{2\pi} \int S_x(f) df = S_x(0) = \infty$$

۳) کامپی با دایرسی ∞ وجود ندارد

۴) low pass LTI و Gaus

Wiener process

AKA Brownian motion process

$\subset CT-GP$

التي $X(t)$ بخلافات $N(t)$ لها اتجاهية تمت

a zero mean GP that has stationary inc. and independent inc. properties ($X(t) \equiv N(t)$)

and $X(0)=0$ and has continuous sample functions wp1 $\{X(t); t \geq 0\}$

continuous stationary

Theorem if $\{X(t); t \geq 0\}$ has stationary inc. and independent inc. and $X(0)=0$

$$\text{then } \forall \tau > t \quad \mathbb{E}[X(t)] = t \mathbb{E}[X(1)] \quad \text{and} \quad \sum_{xx}(t, \tau) = \text{var}(X(t)) \\ = t \text{var}(X(1))$$

فرازد های $t \leq \tau$ $\sum_{xx}(t, \tau)$ با $\sum_{xx}(1, \tau)$ stationary و $\sum_{xx}(t, \tau)$ stationary inc., independent inc. و $\sum_{xx}(1, \tau)$ stationary inc. با $\sum_{xx}(1, \tau)$ stationary inc.

proof

$$t = n\Delta \rightarrow X(n\Delta) = (X(n\Delta) - X((n-1)\Delta)) + \dots + (X(\Delta) - X(0))$$


$$\mathbb{E}[X(n\Delta)] = n \mathbb{E}[X(\Delta)] \quad \checkmark$$

$$\text{var}(X(n\Delta)) = n \text{var}(X(\Delta))$$

$$\sum_{xx}(t, \tau) \stackrel{\Delta \rightarrow 0}{=} \mathbb{E}[X(t)(X(t) + X(\tau-t))] = \underbrace{\mathbb{E}[X^2(t)]}_{\text{var}(X(t))} + \underbrace{\mathbb{E}[X(t)] \mathbb{E}[X(\tau-t)]}_{0 \text{ zero mean}} \\ \rightarrow \sum_{xx}(t, \tau) = t \text{var}(X(1)) \quad \checkmark$$

wp خواص

برخلافات $X(t)$ white noise وجود دارد. از راه های دیگر می سازند



wp دارای دلخواه

→ gives sample path $\tilde{w}(t)$ of sample path $w(t)$ \leftarrow symmetry .

$$T_a \triangleq \inf\{t \mid w(t) \geq a\} \quad \tilde{w}(t) \triangleq \begin{cases} w(t) & t < T_a \\ 2a - w(t) & t \geq T_a \end{cases} \quad \text{gives sample path } \tilde{w}(t) \leftarrow \text{reflection} .$$

standard wp

$$\mathbb{E}[X(1)] = 0, \text{var}(X(1)) = 1 \rightarrow \mathbb{E}[X(t)] = 0, \sum_{xx}(t, \tau) = \text{var}(X(t)) = \min(t, \tau)$$

Markov chain \subset Markov process

$\{x_n \mid n \in \mathbb{Z}_{\geq 0}\}$ where $x_0, \dots \in S$ (state space) and S is countable

- $S = \{1, \dots, M\} \rightarrow$ finite state markov chain
 - $S = \{1, \dots\} \rightarrow$ infinite state markov chain

and $\mathbb{P}(X_n = j \mid X_{n-1} = i, \dots, X_0 = l) = \mathbb{P}(X_n = j \mid X_{n-1} = i)$

Markov process در حالت \oplus
می توان S پیوسته میل IR را
با نیز بخوبی ایجاد کرد \checkmark

⊗ در ادامه صریحاتیست MC مبادرین MC

$$P(x_0 \dots x_n) \xrightarrow{\text{chain rule}} P(x_0) \prod_{i=1}^n P(x_i | x_{i-1} \dots x_0)$$

⊗ تعا اختر ترن state اهمیت داره یعنی:

$$\underline{\text{markov chain}} \quad p(x_0) \sum_{i=1}^n p(x_i | x_{i-1})$$

$$X_n | X_{n-2} \stackrel{\text{I.O.}}{\equiv} X_n | X_{n-2}, X_{n-5}$$

$$\text{initial state distribution } \left[P(X_0=i) \right]_{i=1}^M = \pi_i \xrightarrow{\text{sum}} 1$$

$$\text{transition probability matrix } \left[P(x_{n+1}=j \mid x_n=i) \right]_{i,j=1}^M = \left[\begin{matrix} p_{11} & \dots & p_{1M} \\ \vdots & & \vdots \\ p_{M1} & \dots & p_{MM} \end{matrix} \right] \xrightarrow{\text{sum}} 1 = P$$

حالت حادثه از Random walk \otimes
as markov chain

بعنی همیاره احتمال رزتن از استت i به j بمسان نموده باشیم که P_{ij} نامیده می‌شود.

Definitions

n step walk \rightarrow an ordered string of nodes (i_0, \dots, i_n) $\underline{n \geq 1}$ where $p_{x_0 \dots x_n}(i_0 \dots i_n) > 0$

path \rightarrow a walk in which no nodes are repeated

cyclic \rightarrow a walk in which the first and the last nodes are the same and no other node is repeated

$(i \rightarrow j) \rightarrow$ state j is accessible from i if there is a walk from i to j $\leftarrow \text{iff} \rightarrow \exists n \ p_{ij}^n > 0$

$(i \leftrightarrow j) \rightarrow$ distinct states i, j communicate if $i \rightarrow j$ and $j \rightarrow i$


$$\left. \begin{array}{l} (i \rightarrow j) \quad p_{ij}^n > 0 \\ (j \rightarrow k) \quad p_{jk}^m > 0 \end{array} \right\} \rightarrow p_{ik}^{n+m} \geq p_{ij}^n p_{jk}^m > 0$$

(i → k)

$$P_{ij}^n \triangleq P(x_n=j | x_0=i) \quad \leftarrow$$

از تفا این عبارت برایه اینه که ماریس m رو به توان n برسون
و بعد امانت $[z_n]$ ⁿ رو پردازی !

⊕ به دلیل کسرت بودن در زمان و حالت state و محدود بودن Finite state markov chain ایکیا، من یعنی باید state شاد باشیم گرانی داشته باشیم



⊕ markov chain صورت π^n را که مرتبه 1 درست.

$$S = \{1, \dots, M\} \longrightarrow \tilde{S} = \{(1,1) \dots (M,M)\} : k=2 \text{ داریم}$$

$$|S| = M \qquad |\tilde{S}| = M^2$$

$$P(X_{n+1}=j | X_n=i, X_{n-1}=k) = P(\underbrace{X_{n+1}=j}_{\tilde{X}_{n+1}=(j,i)}, \underbrace{X_n=i}_{\tilde{X}_n=(i,k)} | X_{n-1}=k)$$

⊕ این صورت ماتریس P دارای M^3 درایی است که در M^3 ماتریس M^4 دارای است که M^4 صفر است.

Definitions

class of states \rightarrow a non empty set of states $C \subseteq \{1, \dots, M\}$ such that

if $i \in C$ and $j \neq i$ then if $i \xrightarrow{\text{com}} j \rightarrow j \in C$
and if $i \xleftarrow{\text{com}} j \rightarrow j \notin C$

گراف افزایشی \rightarrow تعداد کلاس و هر دو کلاس با تمام اعضا \rightarrow communicate
کلاس دو دو همچو کلاس \rightarrow \rightarrow communicate

recurrent state \rightarrow state i is recurrent if $i \rightarrow j$ implies $j \rightarrow i$

استیت هایی که آنها بار دیگه بسن
با احتمال 1 بی خواست بار دیگه هم دیگه میشن

transient state \rightarrow a state which is not recurrent

⊕ هر چند هم احتمال دیگه سرنیک state که باشد
اگر صفر نباشد باید با احتمال 1 بالآخره دیگه میشون

periodic state \rightarrow state i which its period

$$d(i) \triangleq \text{GCD}(\{n \geq 1 | P_{ii}^n > 0\}) > 1$$

ابابت میکو و دو دو کلاس
trans. لیکن ای ریک. ریک

ابابت میکو و تمام دو دو کلاس
دو دو میکان دارند period

recurrent class \rightarrow a class where all its states are recurrent

transient class \rightarrow " " " are transient


periodic class \rightarrow " " " are periodic

ergodic class \rightarrow a class where all its states are recurrent and aperiodic

ergodic chain \rightarrow a markov chain consisting only of one ergodic class

⊕ markov chain میتواند یک recurrent class دارد و گزینه half holt فرازیند، بی خواست تناهی بود.

⊕ to be a recurrent class وارد میشون



⊕ اگر یک کلاس باید d باشد، میتوان state های این کلاس را d بجای افزایش کرد پهلوی کو:


⊕ اگر یک periodic بعدن سهند چندی وجود یک جردن کلمع که مطلوب نیست!

⊕ aperiodic \leftarrow اگر یک لحظه داشته باشیم

Theorem

For an ergodic M state markov chain, For all i, j , $m \geq (M-1)^2 + 1$

we have $p_{ij}^m > 0$



این کران بیکم بود از m بزرگتر است
از این که این کران باشد هم بسیار نزدیک است
که این کران باشد هم بسیار نزدیک است
از این که این کران باشد هم بسیار نزدیک است

Matrix Representation

$$[\pi_0] @ [1] = 1$$

$M \times M$ $M \times 1$


$$[P] @ [1] = [1]$$

$M \times M$ $M \times 1$

ماتریس P حداقل یک متار دیگر 1 دارد.
جمع سطرها 1 بود و
تعداد مطلق سایر متار دیگر ها نسبتاً کم است

periodic w/ transient

براید 2



$|u_{kl}| \geq |u_{ij}| \forall j \leftarrow$ پس از u_k , u

$$(Pu)_k = \lambda u_k$$

$$\rightarrow |\lambda| |u_k| = |(Pu)_k| = \left| \sum_{j=1}^M P_{kj} u_j \right|$$

$$\leq \sum_{j=1}^M P_{kj} |u_j| \leq |u_k| \underbrace{\sum_{j=1}^M P_{kj}}_1 \rightarrow |\lambda| \leq 1$$

Steady state of a markov chain

steady state vector π^{ss} for an M -state markov chain
is a row vector that satisfies $\pi^{ss} = \pi^{ss} P$

If $\lambda_0 = 1$ and $\forall i \in \{1, \dots, M-1\}$ $|\lambda_i| < 1$

$$P \xrightarrow{\text{SVD}} \mathbf{1} \pi^{ss} + \sum_{i=2}^M \lambda_i u_i v_i^T \xrightarrow{|\lambda_i| < 1} \lim_{n \rightarrow \infty} P^n = \mathbf{1} \pi^{ss}$$

$$\begin{aligned} \mathbf{1} \pi^{ss} &= \mathbf{1} \rightarrow u_1 = 1 \\ \pi^{ss} P &= \pi^{ss} \rightarrow v_1^T = \pi^{ss} \end{aligned}$$

$$= \begin{bmatrix} -\pi^{ss} \\ \vdots \\ -\pi^{ss} \end{bmatrix}$$

$$\rightarrow \lim_{n \rightarrow \infty} \pi_0 P^n = \pi_0 \mathbf{1} \pi^{ss} = \pi^{ss} \checkmark$$

توسیع $[P]$ به صورت جمع M ماتریس $rank 1$ فرم دیگری داشت

حاله دائم پسین π_0 را در نظر می‌گیریم
مسنون از π_0 بود یعنی این مسئله باید P و π^{ss} هایی داشته باشند.

حاله دائم π_0 را در فرم $\lim_{n \rightarrow \infty} P^n$ در نظر می‌گیریم

و π^{ss} را در فرم $\lim_{n \rightarrow \infty} P^n \pi_0$ در نظر می‌گیریم
که π^{ss} است و مسنون از π_0 است
 π^{ss} را در فرم $\lim_{n \rightarrow \infty} P^n \pi_0$ در نظر می‌گیریم

\star معادله $p = \tau^{55} \tau^{55}$ همیشہ، به ازای مردم، حداقل یک جواب را دارد اما ما درست داریم تفاوک جواب یکتا داشته باشد
تا همواره در $n \rightarrow \infty$ صورت τ^{55} یکتا همگرا شویم.


Lemma: if $\forall i, j \ p_{ij} > 0$ and $\alpha \triangleq \min_{i,j} p_{ij}$

then for all states j and all $n \geq 1$:

$$\max_i p_{ij}^n - \min_i p_{ij}^n \leq (1-2\alpha)^n$$

$$\xrightarrow{h \rightarrow \infty} P^h = \begin{bmatrix} -TC^{ss} \\ \vdots \\ -TC^{ss} \end{bmatrix}$$

یک نیازد : \dot{W} steady state



$$\begin{bmatrix} 0 & 0.5 & 0.5 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0.5 & 0.25 & 0 & 0.25 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 0 & 0.5 & 0.5 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

یوون ھلکاری H_m روتوب ہے کہ periodic

$$\lim_{n \rightarrow \infty} p^n \quad \text{اگر } P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

بین [۱۰] و [۱۱] نویسان می‌کند.
آن در مهان است که $\frac{۲۲}{۳۳}$ یعنی $\frac{۲}{۳}$.

$$\text{معادله} \quad \textcircled{4} \quad \pi_{\text{ss}} = \pi^{\text{ss}} \text{ میگذرد اگر: } \frac{\pi_{\text{ss}}}{\pi^{\text{ss}}} \equiv \text{استقرار از} \quad \text{استقرار از}$$

$$1 = |\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_m| \quad \text{فقط، لأن } \lambda_i \in \mathbb{R}.$$

• سرطانی: $P_{ij} > 0$ یعنی از هر استئینی به هر استئینی V_{ij} طور ممکن است منتقل شود.

- Markov chain being ergodic : Gibbsian •

ergodic \Rightarrow for $n \geq (M-1)^2 + 1$ $\forall i, j \quad p_{ij}^n \geq \beta > 0$

$$\rightarrow \max_i p_{ij}^n - \min_i p_{ij}^n \leq (1-2\beta)^{\lfloor \frac{n}{(M-1)^2+1} \rfloor}$$

initialization π^0 , π^0 steady state π^* and gap $\lambda_1 - \lambda_2$ بـ زمانی که نسبت داده شوند \Rightarrow
 ازین بروکر گزینه بزرگ است $\text{spectral gap} = 1 - |\lambda_2| \geq 0$. mixing time t_{mix} باشد
 اولین زمانی π^0 \rightarrow π^* تغییر نماید \Rightarrow mixing time t_{mix}

irreducible MC \rightarrow قابل انتقال نهایی \rightarrow قابل انتقال مختلط \rightarrow قابل انتقال مختلط با هم \rightarrow irreducible MC

ρ^n is also, by π^{ss} \leftarrow irreducible + aperiodic

Reversibility

a markov chain that has a unique $\pi^{ss} = \lim_{n \rightarrow \infty} \pi_0 P^n$
 is reversible in time if $\pi_i j$

$$\pi^{ss}(i) p_{ij} = \pi^{ss}(j) p_{ji}$$

Estimation

data \rightarrow model

parametric Estimation

$$\{x_1, \dots, x_n\} \stackrel{iid}{\sim} P_{\theta}$$

$$\begin{array}{c} N(\mu, \sigma^2) \\ \uparrow \\ P_{\theta} \in \mathcal{P} \end{array} \quad \begin{array}{c} N \\ \uparrow \\ \theta \in \Theta \end{array} \quad \begin{array}{c} [\mu] \\ \uparrow \\ \sigma^2 \end{array} \quad \begin{array}{c} [] \\ \uparrow \\ \mathbb{R} \times \mathbb{R}_+ \end{array}$$

$$\theta^* \in \Theta \quad x_1, \dots, x_n \stackrel{iid}{\sim} P_{\theta^*}$$

$$\begin{array}{c} \mathcal{P} = \{P_{\theta} \mid \theta \in \Theta\} \\ \text{distribution family} \quad \text{parameter space} \\ \text{parameter vector} \end{array}$$

Goal: create an estimator $\hat{\theta}(x_1, \dots, x_n)$

$$\hat{\theta}: \bigcup_{i=1}^{\infty} X^i \rightarrow \Theta$$

نمونه‌های پارامترها

نمونه‌های دیاستها

Non-parametric Estimation

\otimes در تخمین پارامتریک خانواده‌ی توزیع ثابت و اولانه‌ی بودار θ محدوده اما در تخمین غیرپارامتریک مسیمه اولانه‌ی θ در بی‌نهایت در نظر گرفته

$$\text{approx. error} = 0$$

$$x_1, \dots, x_n \stackrel{iid}{\sim} P_{\theta^*}$$

$$\theta^* \in \Theta$$

randomness $\hat{\theta}$ می‌تواند یک تابع θ باشد و یا اینکه deterministic باشد $\hat{\theta}$ \otimes
هم داشته باشند اما در این درون ممکن است $\hat{\theta}$ کار داشته باشد

\otimes تخمین پارامتریک مسیمه θ \otimes

\otimes overfitting \otimes

\otimes تخمین غیرپارامتریک مسیمه θ \otimes

\otimes اور $\hat{\theta}$ نسبت به θ \leftarrow estimation error \otimes

اور حاصل از انتخاب خانواده \leftarrow approximation error \otimes

$$\text{بد برای } P$$

$$n, P, \Theta, \dots, \theta^* \text{ تابع است از } \mathbb{E}_{x_1, \dots, x_n \stackrel{iid}{\sim} P_{\theta^*}} [\hat{\theta}(x_1, \dots, x_n)] \otimes$$

$$\bullet \text{ Bias}(n, \theta^*) \triangleq \mathbb{E}_x [\hat{\theta}(x_1, \dots, x_n)] - \theta^*$$

\otimes اگر $\hat{\theta}, \theta^*$ بوداری باشند، بایاس و دارای هم بودار می‌شون

\otimes بایاس می‌تواند هم بشه. ما بیشتر با $|\text{bias}|$ طیم

\otimes experiment از ایک الگوریتم تخمین تعیین می‌کنیم که نتیج

\otimes بایاس به ازای یک الگوریتم تخمین تعیین می‌کنیم که نتیج

$$P = \{N(\theta, \sigma^2) \mid \theta \in \Theta\}$$

$$x_1, \dots, x_n \stackrel{iid}{\sim} N(\mu^*, \sigma^2)$$

\otimes تخمین برای میانگین کاویسی با دارایی ثابت:

$$\hat{\mu}_1 = \frac{x_1 + \dots + x_n}{n} \quad \begin{array}{l} \text{sample mean} \\ \text{empirical mean} \end{array}$$

$$\text{Bias}(n, \mu^*) = \mu^* - \hat{\mu}_1 = 0$$

$$\text{var}(n, \mu^*) = \mathbb{E}_x \left[\left(\frac{x_1 + \dots + x_n}{n} - \mu^* \right)^2 \right] = \mathbb{E}_x \left[\left(\frac{1}{n} \sum_{i=1}^n (x_i - \mu^*) \right)^2 \right] = \frac{1}{n^2} \sum_{i,j=1}^n \mathbb{E}_x [(x_i - \mu^*)(x_j - \mu^*)]$$

$$= \frac{1}{n^2} \sum_{i=1}^n \mathbb{E}_x [(x_i - \mu^*)^2] = \frac{\sigma^2}{n}$$

$$\hat{\mu}_2 = \bar{X}_1$$

$$\text{Bias}(n, \mu^*) = 0$$

$$\text{Var}(n, \mu^*) = E[(\bar{X}_1 - \mu^*)^2] = \sigma^2$$

$$\hat{\mu}_4 = 5$$

$$\text{Bias}(n, \mu^*) = 5 - \mu^*$$

$$\text{Var}(n, \mu^*) = 0$$

$$\hat{\mu}_3 = \frac{n\bar{X}_n + (n-1)\bar{X}_{n-1} + \dots + \bar{X}_1}{\frac{n(n+1)}{2}}$$


$$\text{Bias}(n, \mu^*) = 0$$

$$\text{Var}(n, \mu^*) = \left(\frac{2}{n(n+1)}\right)^2 \left[n^2 \frac{\sigma^2}{\text{Var}(X_n)} + \dots + \frac{\sigma^2}{\text{Var}(X_1)} \right]$$

$$= \frac{2}{3} \frac{2n+1}{n(n+1)} \sigma^2 \approx \frac{4}{3} \frac{\sigma^2}{n}$$

بعد از empirical mean چهو

Bias Variance Dilemma



For unbiased $\hat{\theta}$ we have Cramer-Rao lower bound:

$$\text{Var}_{\hat{\theta}}(n, \theta) \geq \frac{1}{n I(\theta)}$$

fisher information

$$\begin{aligned} I(\theta) &\triangleq E_x \left[\left(\frac{\partial \log f_{\theta}(x)}{\partial \theta} \right)^2 \right] \\ &= E_x \left[- \frac{\partial^2}{\partial \theta^2} \log f_{\theta}(x) \right] \geq 0 \end{aligned}$$

bias \equiv estimation error

var \equiv approximation error

⊗ حذی تجین پارامتریک این که با افزایش بعد داده هار جار نگیریم. مثلاً اگر برای کادسی یک بعدی با $O(d)$ سهل باشیم، تجی متناسب برسیم، برای کادسی d بعدی هم با $O(d^2)$ سهل باشیم تجی متناسب برسیم.

تعداد پارامتر های کادسی d بعدی

overfitting \equiv وابستگی بالا

Maximum Likelihood Estimation

$$\hat{\theta}_{MLE} \triangleq \underset{\theta \in \Theta}{\operatorname{argmax}} \prod_{i=1}^n p_\theta(x_i)$$

یک مجموعه سالم \mathcal{S} دارد و \mathcal{S} را با این حالت کاری نمایم.

* MLE نزدن مولن $\hat{\theta}$ ها سنت آند دلی اگر نباشد هم مینه اونه استفاده کرد. فقط یکسری از ویرگ های را از دست میده.

$$\bullet X_1, \dots, X_n \stackrel{\text{ iid }}{\sim} N(\theta, \sigma^2)$$

$$\hat{\theta}_{MLE} = \underset{\theta \in \mathbb{R}}{\operatorname{argmax}} \sum_{i=1}^n f_\theta(x_i) = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \lg f_\theta(x_i) = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n - (x_i - \theta)^2 \stackrel{\frac{d}{d\theta} = 0}{=} \bar{x}_n$$

$$\bullet X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2) \quad \text{unknown}$$

$$(\hat{\mu}, \hat{G}) = \underset{\mu \in \mathbb{R}}{\operatorname{argmax}} \sum_{i=1}^n \lg \frac{1}{G} - \frac{1}{2G^2} (x_i - \mu)^2 + \text{const}$$

$$\frac{d}{dr} = 0 \rightarrow \hat{\mu}_{MLE} = \bar{X}_n \quad \begin{array}{l} \text{bias} = 0 \\ \text{var} = \frac{\sigma^2}{n} \end{array} \quad \text{consistent} /$$

$$\frac{d}{dG} \hat{G}^2_{MLE} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2$$

Graw Graw

$$\mathbb{E}[\hat{\sigma}_{MLE}^2] = \frac{\mathbb{E}[x_i^2]}{n} + \frac{\mathbb{E}[\bar{x}_n^2]}{n} - 2\frac{\mathbb{E}[x_i\bar{x}_n]}{n}$$

$$\rightarrow \text{Bias}(\hat{\sigma}_{\text{MLE}}^2) = \frac{-\sigma^2}{n} \neq 0$$

: $\hat{\sigma}_{MLSE}^2$ is unbiased

$$\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2 \text{ is unbiased}$$

حالاً $\hat{\mu}_{MLE}$ میکنیں $\hat{\mu}_{MLE} = \bar{X}_n$ و دارای توزیع MLE را داریم

نگاهی خالب انتہا

$$\text{Bias}(\hat{\sigma}_{\text{MLE}}^2) = 0$$

هیچ‌یه بایس داده و لئن از λ^2 نه چون آن
 $\lambda_{\min} \dots \lambda_1$ در دست، مقدار M متاخر نیاشن
 λ معدن رو طوری تفکم می‌کنه که درست پشته
 و بنا بر این $(X_i - \bar{X}_n)^2$ همراه از $(M - i)$

وَمَنْ يُعَذِّبُ إِلَّا هُوَ أَعَزُّ
وَمَنْ يُحْكِمُ إِلَّا هُوَ أَعْلَمُ
وَمَنْ يُنَزِّلُ إِلَّا هُوَ أَعْلَمُ


$$ج(\hat{\theta}_{MLE}) = \hat{g}(\theta)_{MLE}$$

لذا $\hat{\theta}_{MLE}$ رسمیاً $\hat{\theta}_{MLE}^2$ و محااسبه کرد بعد با همان روشین بـ $(\hat{\theta}_{MLE})^2$ رسید که همچنین!

ولی خوب مکالمہ باپاں مریط ہے تھیں ٹھیک نہیں جوون گ لرزما سنی نہست و لے اُرث رہ نہیں؟

⊗ براي کادری میانگین تمرکزهای unbiased تئوری واریانس داده

- $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Unif}(0, \theta) \quad \theta > 0$



$$\hat{\theta}_{MLE} = \underset{\theta > 0}{\operatorname{argmax}} \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}(X_i \leq \theta) = \max \{X_1, \dots, X_n\}$$

کوچکترین θ که $f_\theta(x_i)$ مثبت باشد

$$\rightarrow F_{\hat{\theta}_{MLE}}(x) = F_x(x)^n \rightarrow f_{\hat{\theta}_{MLE}}(x) = n \underbrace{F_x(x)^{n-1}}_{\left(\frac{n}{\theta} \mathbb{1}(0 \leq x \leq \theta)\right)^{n-1}} f_x(x) = \frac{n}{\theta} \left(\frac{x}{\theta}\right)^{n-1} \quad 0 \leq x \leq \theta$$

$$\rightarrow \text{Bias}(n, \theta) = \int_0^\theta \frac{n}{\theta} \left(\frac{x}{\theta}\right)^{n-1} n dx - \theta = \frac{n\theta}{n+1} - \theta = \frac{-\theta}{n+1}$$

برآوردگر under estimate منتهی گیری

پس از unbiased تبدیل $\hat{\theta}_{custom} \triangleq \frac{n+1}{n} \hat{\theta}_{MLE}$ شود

- $X_1, \dots, X_n \stackrel{iid}{\sim} Exp(\lambda) \quad \lambda > 0$

$$\hat{\lambda}_{MLE} = \underset{\lambda > 0}{\operatorname{argmax}} \prod_{i=1}^n \lambda e^{-\lambda X_i} = \underset{\lambda > 0}{\operatorname{argmax}} n \lg \lambda - \lambda \sum_{i=1}^n X_i$$

$$\frac{d}{d\lambda} = 0 \rightarrow \hat{\lambda}_{MLE} = \frac{n}{\sum_{i=1}^n X_i} \rightarrow \hat{\mu}_{MLE} = \frac{1}{\hat{\lambda}_{MLE}} = \bar{X}_n$$

Cramer - Rao Lower Bound and Fisher Information

If $x_1, \dots, x_n \stackrel{iid}{\sim} f_\theta(x)$ and for $\hat{\theta}$ which is unbiased then $\text{Var}_{\hat{\theta}}(n, \theta) \geq \frac{1}{n I(\theta)}$ if $0 < I(\theta) < \infty$

proof for $n=1$

$$\mathbb{E}\hat{\theta} - \theta = 0 \rightarrow \int (\hat{\theta} - \theta) f_\theta(x) dx = 0 \xrightarrow{\frac{d}{d\theta}} \int (\hat{\theta} - \theta) \frac{d f_\theta(x)}{d\theta} dx - \underbrace{\int f_\theta(x) dx}_1 = 0 \quad (I)$$

$$\frac{d}{d\theta} \lg f_\theta(x) = \frac{f'_\theta(x)}{f_\theta(x)} \rightarrow \frac{d f_\theta(x)}{d\theta} = f_\theta(x) \cdot \frac{d}{d\theta} \lg f_\theta(x) \quad (II)$$

$$\xrightarrow{\text{sub } (II)} \int (\hat{\theta} - \theta) f_\theta(x) \frac{d}{d\theta} \lg f_\theta(x) dx = 1$$

$$\begin{aligned} I(\theta) &\triangleq \mathbb{E}_x \left[\left(\frac{d \lg f_\theta(x)}{d\theta} \right)^2 \right] \\ &= \mathbb{E}_x \left[-\frac{d^2}{d\theta^2} \lg f_\theta(x) \right] \geq 0 \end{aligned}$$

$$\xrightarrow[\text{cauchy-schwarz}]{\text{Cauchy-Schwarz}} \underbrace{\left(\int (\hat{\theta} - \theta) \sqrt{f_\theta(x)} \sqrt{f_\theta(x)} \frac{d}{d\theta} \lg f_\theta(x) dx \right)^2}_1 \leq \underbrace{\int (\hat{\theta} - \theta)^2 f_\theta(x) dx}_{\text{Var}_{\hat{\theta}}(1, \theta)} \cdot \underbrace{\int f_\theta(x) \left(\frac{d}{d\theta} \lg f_\theta(x) \right)^2 dx}_{\text{Var}_{\hat{\theta}}(1, \theta)}$$

لأن CR if $I(\theta) = 0$ or ∞ $\hat{\theta}$ Fisher Information \rightarrow
 . $\hat{\theta}$ مترافق $I(\theta)$ ، $\hat{\theta}$ مترافق $\frac{d \lg f_\theta(x)}{d\theta}$ $\leftarrow I(\theta) \rightarrow \frac{d}{d\theta}$ $\hat{\theta}$ \rightarrow
 . $\hat{\theta}$ مترافق $I(\theta)$ \rightarrow مترافق $f_\theta(x)$ نسبت $\hat{\theta}$ \rightarrow مترافق $\hat{\theta}$ \rightarrow مترافق $I(\theta)$.

- ⊕ if $\theta \in \mathbb{R} \rightarrow I(\theta) \in \mathbb{R}_{\geq 0}$
- ⊕ if $\theta \in \mathbb{R}^k \rightarrow I(\theta) \in \mathbb{R}^{k \times k}$ \rightarrow مترافق

MLE properties

- always consistent
- if x_1, \dots, x_n are iid from f_θ it has asymptotic normality (gaussianity)

$$\text{i.e. } \sqrt{n} (\hat{\theta}_{\text{MLE}}(x_1, \dots, x_n) - \theta) \xrightarrow[n \rightarrow \infty]{\text{I.D.}} \mathcal{N}\left(0, \frac{1}{I(\theta)}\right)$$

$$\xrightarrow{\text{Corollary}} \lim_{n \rightarrow \infty} \text{Var}_{\hat{\theta}_{\text{MLE}}} = \frac{1}{n I(\theta)}$$

لأن $\hat{\theta}_{\text{MLE}}$ مترافق \rightarrow غير مترافق $\hat{\theta}_{\text{MLE}}$ \rightarrow غير مترافق


لأن $\hat{\theta}_{\text{MLE}}$ غير مترافق \rightarrow غير مترافق $\hat{\theta}_{\text{MLE}}$ \rightarrow غير مترافق

asymptotic normality يوخارى \oplus

consistency خواص


باختصار $\hat{\theta}_{\text{MLE}} - \theta$ مترافق

مترافق $\frac{1}{\sqrt{n}}$ دارالدالة



لأن $\hat{\theta}_{\text{MLE}}$ غير مترافق \rightarrow غير مترافق $\hat{\theta}_{\text{MLE}}$ \rightarrow غير مترافق

لأن $\hat{\theta}_{\text{MLE}}$ غير مترافق \rightarrow غير مترافق $\hat{\theta}_{\text{MLE}}$ \rightarrow غير مترافق



نتیجه از اینکه $\hat{\theta}_{\text{custom}}$ نسبت به $\hat{\theta}_{\text{CR}}$ نسبت به $\hat{\theta}_{\text{MVUE}}$ کمترین واریانس را دارد
 برای بعضی از مسائل MVUE سونه هست که با CR نسبت به minimum variance unbiased estimator (MVUE) بودن
 همچنان که CR efficient نباید باشد و دارای این واریانس هم کمترین است



Fisher Information of $P = \{N(\mu, \sigma^2) \mid \mu \in \mathbb{R}\}$

$$I(\mu) = E_x \left[\left(\frac{\partial}{\partial \mu} \log \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \right) \right)^2 \mid \mu, \sigma^2 \right] = E_x \left[\left(\frac{\mu - x}{\sigma^2} \right)^2 \right] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}$$

$$\rightarrow \text{Var}_{\mu}(\hat{\mu}, \mu) \geq \frac{\sigma^2}{n}$$

هرچند داریم $\hat{\mu}$ نسبت به μ نسبتاً میزانیست

Fisher Information of $P = \{Unif(0, \theta) \mid \theta > 0\}$

assume unbiased estimator $\hat{\theta}_{\text{custom}} = \frac{n+1}{n} \max X_i$

$$\text{Var}(\hat{\theta}_{\text{custom}}) = E[\hat{\theta}^2] - \theta^2$$


$$= \left(\frac{n+1}{n} \right)^2 \underbrace{\int_0^\theta \frac{n}{\theta} \left(\frac{n}{\theta} \right)^{n-1} n^2 \, dn}_{\frac{(n+1)^2 \theta^2}{n^2(n+2)}} - \theta^2 = \frac{\theta^2}{n(n+2)} = O\left(\frac{1}{n^2}\right)$$

چون $\hat{\theta}_{\text{custom}}$ نسبت به θ نسبتاً میزان است
اما $\hat{\theta}_{\text{custom}}$ برای توزیع Unif تعیین نمیشود!

چون $\hat{\theta}_{\text{custom}}$ نسبت به θ نسبتاً میزان است
و دارای این میزان است
 $I(\theta) = \infty$

$I(\theta) = \infty$ در حقیقت برای توزیع $Unif(0, \theta)$ نسبت به θ نسبتاً میزان است
هرچند $\hat{\theta}_{\text{custom}}$ نسبت به θ نسبتاً میزان است

given a snapshot of a poisson process with length T, estimate its λ



(assuming $x_1 \leq x' \leq x_1 + x_2 + \dots + x_n$ (so interarrival) \Rightarrow $x' = \sum x_i + n$) 1 of 1

$$\begin{aligned}\hat{\lambda}_{MLE} &= \underset{\lambda > 0}{\operatorname{argmax}} \quad f_{snapshot(T)} = \underset{\lambda > 0}{\operatorname{argmax}} \prod_{i=1}^n \lambda e^{-\lambda x_i} e^{-\lambda x'} \\ &= \underset{\lambda > 0}{\operatorname{argmax}} \lambda^n e^{-\lambda(\sum_{i=1}^n x_i + x')} = \underset{\lambda > 0}{\operatorname{argmax}} \lambda^n e^{-\lambda T} = \frac{n}{T}\end{aligned}$$

- $Bias(\hat{\lambda}_{MLE}) = \frac{\mathbb{E}[\lambda]}{T} - \lambda$

$= \frac{\lambda T}{T} - \lambda = 0$

($\sim \text{poisson}(\lambda T)$ توزیع داریم) 2 of 1

$$\begin{aligned}\hat{\lambda}_{MLE} &= \underset{\lambda > 0}{\operatorname{argmax}} \quad f_{snapshot(T)} = \underset{\lambda > 0}{\operatorname{argmax}} \frac{(\lambda T)^n}{n!} e^{-\lambda T} \\ &= \underset{\lambda > 0}{\operatorname{argmax}} \text{const} \times \lambda^n e^{-\lambda T} = \frac{n}{T}\end{aligned}$$

fisher inf. $\left(\frac{\partial}{\partial \lambda} \ln f_{snapshot(T)} \right) = \mathbb{E}_n \left[-\frac{\partial^2}{\partial \lambda^2} (\ln \lambda - \lambda T) \right]$

 $= \mathbb{E}_n \left[\frac{n}{\lambda^2} \right] = \frac{\lambda T}{\lambda^2} = \frac{T}{\lambda}$

تعداد x_i , n نامناسب است \otimes

$\text{var}(\hat{\lambda}_{MLE}) = \frac{1}{T^2} \frac{1}{I(\lambda)}$

کافی CR efficient

condition x_1, \dots, x_n از λ بسته باشند \otimes
این $\sim \text{Unif}(0, T)$ است x_i از λ مستقل نیست

این بدل برای λ استimation کوچک است

این تعداد سه λ است $\lambda = \bar{x}$ برابر 1 است
برای همین $\text{var}(\hat{\lambda}_{MLE}) \approx n$ نامناسب است.

For parametric estimation

Sufficient statistic

a statistic is a function of random samples x_1, \dots, x_n e.g. $\bar{x}_n, \max x_i, n$



T is a sufficient statistic if by knowing T we can do as good a job of estimating θ as by knowing the entire random sample x_1, \dots, x_n

a statistic $T = r(x_1, \dots, x_n)$ is a sufficient statistic if

$\forall t \quad P(\underline{x} | T=t, \theta) = P(\underline{x} | T=t)$

$P = \{N(\mu, \sigma^2) \mid \mu \in \mathbb{R}, \sigma > 0\} \longrightarrow T(\underline{x}) = (\sum x_i, \sum x_i^2) \text{ or } (\frac{\text{sample mean}}{\text{sample var}})$

suff. stat. \otimes
یک نیست

$P = \{\text{Unif}(a, b) \mid a < b \in \mathbb{R}\} \longrightarrow T(\underline{x}) = (\min x_i, \max x_i)$

$P = \{\text{poisson process } (\lambda) \mid \lambda > 0\} \longrightarrow T(\underline{x}) = n$

suff. stat. \otimes
ویرگی مانند دیگر توزیع است
و در ورد توزیع دلیل ندارد!

Fisher - Neyman Factorization Theorem

Let \underline{X} be a random sample with joint density $f_\theta(\underline{X})$, then T is sufficient for θ iff

$$\exists g, h \geq 0 \quad f_\theta(x) = h(x) g_\theta(T(x))$$

$\rightsquigarrow h$ must not depend on θ

$\rightsquigarrow g$ can depend on x only through $T(x)$

$$\begin{aligned} \underline{x} \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2) &\xrightarrow{\text{fix}} f_{\mu}(x) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \prod_{i=1}^n e^{-\frac{1}{2\sigma^2}(x_i - \mu)^2} \\ &= \underbrace{\left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 \right]}_{h(\underline{x})} \cdot \underbrace{\exp \left[\frac{1}{\sigma^2} \left(\sum_{i=1}^n x_i \right) \mu - \frac{n\mu^2}{2\sigma^2} \right]}_{g_{\mu} \left(\frac{\sum x_i}{T(\underline{x})} \right)} \end{aligned}$$

Rao - Blackwell's Theorem

Let $\hat{\theta}$ be an estimator of θ with $E_x[\hat{\theta}^2] < \infty$ for all θ . Suppose T is sufficient for θ and let $\tilde{\theta} \triangleq E_x[\hat{\theta}(\underline{x}) | T(\underline{x})]$ then

$$\forall \theta \quad \text{MSE}(\hat{\theta}, \theta) = \mathbb{E}_{\hat{x}}[(\hat{\theta} - \theta)^2] \leq \mathbb{E}_{\hat{x}}[(\hat{\theta} - \theta)^2] = \text{MSE}(\hat{\theta}, \theta)$$

$$\text{for unbiased } \tilde{\theta} \rightarrow \text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta})$$

برای مساله متغیر تصادفی X_1, X_2, \dots, X_n داده شده و سهیل های λ , θ را در اینجا تعریف کنیم که $\hat{\theta} = \bar{X}$ است. $\hat{\lambda} = \sum_{i=1}^n X_i$ را بجزی λ و $\hat{\theta} = \bar{X}$ را بجزی θ در مجموع n ترازی دانیم که $\hat{\lambda}$ suff. stat. است.

$$\begin{aligned}\tilde{\theta} &= E_X \left[\hat{\theta} \mid \sum_{i=1}^n X_i = S_n \right] = P(X_i = 0 \mid \sum_{i=1}^n X_i = S_n) \\ &= \frac{P(X_i = 0)}{P(\sum_{i=1}^n X_i = S_n)} = \frac{e^{-\lambda} \frac{(n\lambda)^{S_n}}{S_n!} e^{-(n-1)\lambda}}{\frac{(n\lambda)^{S_n}}{S_n!} e^{-n\lambda}} = \left(1 - \frac{1}{n}\right)^{S_n}\end{aligned}$$

$$\lim_{n \rightarrow \infty} \tilde{\theta} = \lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right)^{S_n} \simeq \lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right)^{n\lambda} = e^{-\lambda} \longrightarrow \tilde{\theta} \text{ is consistent}$$

$$E\tilde{\theta} = E_x \left[\left(1 - \frac{1}{n}\right)^{S_n} \right] \xrightarrow{S_n \sim \text{Poisson}(n\lambda)} \sum_{k=0}^{\infty} \left(1 - \frac{1}{n}\right)^k \frac{(\lambda n)^k}{k!} e^{-\lambda n} = e^{-\lambda n} \underbrace{\sum_{k=0}^{\infty} \frac{[\lambda(n-1)]^k}{k!}}_{e^{\lambda(n-1)}} = e^{-\lambda}$$

$\tilde{\theta}$ is unbiased

$$(\hat{e}^{-\lambda})_{MLE} = e^{-\hat{\lambda}_{MLE}} = e^{-\frac{s_n}{n}}$$

: $\hat{\theta}$ 为 MLE ! $\hat{\theta} = \mathbb{1}[x_i=0]$ 为 0 < λ > 1

$$\lim_{n \rightarrow \infty} \hat{\theta}_{MLE} = \lim_{n \rightarrow \infty} e^{-\frac{s_n}{n}} = e^{-\frac{\lambda n}{n}} = e^{-\lambda} \longrightarrow \hat{\theta}_{MLE} \text{ is consistent}$$


$$\mathbb{E} \hat{\theta}_{MLE} = \mathbb{E}_x \left[e^{-\frac{s_n}{n}} \right] = \sum_{k=0}^{\infty} e^{-\frac{k}{n}} \frac{(\lambda n)^k}{k!} e^{-\lambda n} = e^{-\lambda n} \underbrace{\sum_{k=0}^{\infty} \frac{[e^{-\frac{1}{n}} \lambda n]^k}{k!}}_{e^{e^{-\frac{1}{n}} \lambda n}} = e^{\lambda(n e^{-\frac{1}{n}} - n)} = e^{-\lambda} e^{\lambda o(\frac{1}{n})}$$

$\hat{\theta}_{MLE}$ is biased

Bayesian Estimation

$$\begin{cases} \theta^* \sim f_\theta(\theta) & \xrightarrow{\text{prior distribution}} \\ x_1, \dots, x_n \mid \theta^* \stackrel{iid}{\sim} f_{\theta^*}(x) & \xrightarrow{\text{likelihood}} \\ \rightarrow f(\theta \mid x_1, \dots, x_n) & \xrightarrow{\text{posterior distribution}} \end{cases}$$

$$\begin{cases} n=1 & f(\theta \mid x_1, \dots, x_n) \approx f(\theta) \\ n \rightarrow \infty & f(\theta \mid x_1, \dots, x_n) \rightarrow \delta(\theta - \theta^*) \end{cases}$$



اینها ب طور خاص فرضیه تابع محاسبه بودند

$$p \sim \text{Unif}(0,1) = \mathbb{1}(0 \leq p \leq 1)$$

$$x_1, \dots, x_n \mid p \stackrel{iid}{\sim} \text{Bern}(p) = \prod_{i=1}^n (1-p)^{1-x_i} p^{x_i}$$

$$\rightarrow f_{p \mid x_1, \dots, x_n} = \frac{\Gamma((1-p)^{1-x_i} p^{x_i}) \mathbb{1}(0 \leq p \leq 1)}{\int_0^1 \Gamma((1-p)^{1-x_i} p^{x_i}) dp} = \frac{(1-p)^{n-\sum x_i} p^{\sum x_i}}{g(n, \sum x_i)}$$

$$\begin{aligned} & \text{اینها ب طور خاص فرضیه تابع محاسبه بودند} \\ & \int_0^1 p^\alpha (1-p)^\beta dp \\ & = \frac{\Gamma(\alpha+1) \Gamma(\beta+1)}{\Gamma(\alpha+\beta+2)} \end{aligned}$$

و در این محاسبه فرضیه برای کار نمی‌شود.

برای دست آوردن $\hat{\theta}$ از توزیع $f(\theta \mid x_1, \dots, x_n)$ کارهای مختلف ممکن است:

نیاز به محاسبه فرضیه نیست همان‌طور $\hat{\theta}$ ندارد و در مسئله کمتر صرف می‌شود.

بعضی مواقع نرم‌افزار توزیع را نمایم که \max نماید و محاسبه کنید
توزیعی مثل غایی سیم θ نماید و با این توزیع کلا ignore می‌شود.

موافقی که توزیع را نمایم ولی این sample داریم که \bar{x} داشتیم و پس موند $\hat{\theta}_{MAP} \triangleq \arg \max_{\theta} f(\theta \mid x_1, \dots, x_n)$.

آخر توزیع θ کسته باشد مگرنه می‌خواهد θ را در محدوده Θ نیست.

consistency \oplus
روزنایی bayesian
متقارنی دارد زیرا باید حد
یک R.V. کفته شود.

در روش‌های تخمین bayesian خود θ تصادی نظریه نظریه بنا بر این bias, variance و بنا بر این $E[\text{var}]$, $E[\text{bias}]$ را محاسبه می‌کنیم.

دست شد که سپل‌ها given θ از هم مستقل اند بنا بر این: $f(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i)$.
اصلی برای همین نظریه روابط از طریق marginalization دست باریم.

Maximum A posteriori

$$\hat{\theta}_{MAP} \triangleq \underset{\theta}{\operatorname{argmax}} f(\theta | x_1, \dots, x_n) = \underset{\theta}{\operatorname{argmax}} \frac{f(x_1, \dots, x_n | \theta) f(\theta)}{f(x_1, \dots, x_n)} = \underset{\theta}{\operatorname{argmax}} \lg f(\theta) + \sum_{i=1}^n \lg f(x_i | \theta)$$

$$M \sim \mathcal{N}(M_0, \sigma_0^2)$$

$$x_1, \dots, x_n | M \stackrel{\text{fix}}{\sim} \mathcal{N}(M, \sigma^2)$$

$$\rightarrow \hat{\mu}_{MAP} = \underset{\mu \in \mathbb{R}}{\operatorname{argmax}} \lg \left(\frac{1}{\sqrt{2\pi}\sigma_0} e^{-\frac{(M-M_0)^2}{2\sigma_0^2}} \right) + \sum \lg \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} \right)$$

$$= \underset{\mu}{\operatorname{argmin}} \left(\frac{M-M_0}{\sigma_0} \right)^2 + \sum_{i=1}^n \left(\frac{x_i-\mu}{\sigma} \right)^2 \xrightarrow{\frac{d}{d\mu}=0} \hat{\mu}_{MAP} = \frac{\frac{1}{\sigma_0^2} M_0 + \frac{n}{\sigma^2} \left(\frac{1}{n} \sum x_i \right)}{\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}}$$

با میانگین درن دار \bar{x}_n
و میانگین درن M_0
و سینه که با n بستگی دارد
بستگی دارد

: درن های سینه عقب اگر درزیغ سین درن ها $f(\theta)$ را توزیع لابلس مونت کنیم، درن ها را می سووند sparse initialization \otimes

$$\theta_j \stackrel{\text{ iid }}{\sim} \text{Laplace}(\lambda) = \frac{\lambda}{2} e^{-\lambda |\theta_j|}$$

$$\hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} \underbrace{\lg \left(\prod_{j=1}^J \frac{\lambda}{2} e^{-\lambda |\theta_j|} \right)}_{-\lambda \sum |\theta_j|} + \sum_{i=1}^n \lg f(x_i | \theta) \equiv \text{Lasso Regression}$$

\equiv regularization term

$$\theta_j \stackrel{\text{ iid }}{\sim} \mathcal{N}(0, 1)$$

$$\hat{\theta}_{MAP} = \underset{\theta}{\operatorname{argmax}} \underbrace{\lg \left(\prod_{j=1}^J \frac{1}{\sqrt{2\pi}} e^{-\frac{(\theta_j)^2}{2}} \right)}_{-\frac{1}{2} \sum \theta_j^2} + \sum_{i=1}^n \lg f(x_i | \theta) \equiv \text{Ridge Regression}$$

\equiv regularization term

Mean posterior

$$\hat{\theta}_{MP} \triangleq \mathbb{E}[\theta | x_1, \dots, x_n] = \int \theta f(\theta | x_1, \dots, x_n) d\theta = \frac{\int \theta \left(\prod_{i=1}^n f(x_i | \theta) \right) f(\theta) d\theta}{\int \left(\prod_{i=1}^n f(x_i | \theta) \right) f(\theta) d\theta}$$

\otimes دقت شود که استفاده از توزیع prior سخا در صورتی باعث بجود می شود که source data از data جدید باشد.

\otimes NLE بود که برایش کارانه مای وجود داشت.

Conjugate prior

session 25
1403.3.5

If given a likelihood function $f(x|\theta)$, the posterior distribution $f(\theta|x)$ is in the same probability distribution family as the prior $f(\theta)$, the prior is called a conjugate prior w.r.t that likelihood function.

الآن نعلم أن إذا كانت دالة ال象 تكن من العائلة ذات المقدمة المعرفة $f(x|\theta)$ ، فإن المقدمة المعرفة $f(\theta|x)$ هي مقدمة معرفة $f(\theta)$ ، وهذا ينطبق على MP ، MAP ، MLE .

" $f(\theta)$ هي دالة ال Likelihood ، فـ $f(\theta|x)$ هي دالة ال Likelihood ، وهذا ينطبق على MP ، MAP ، MLE ."

جودة دالة conjugate distribution هي دالة likelihood ، $\rightarrow f(\theta) \in \mathcal{L}$

$$p \sim \text{Beta}(\alpha, \beta)$$

$$x_1, \dots, x_n | p \stackrel{iid}{\sim} \text{Bern}(p)$$

$$\rightarrow p | x_1, \dots, x_n \sim \text{Beta}(\alpha + \sum x_i - 1, \beta + n - 1 - \sum x_i)$$

$$\boxed{\text{proof}} \quad f(p|x) = \frac{f(x|p) f(p)}{f(x)} = \frac{\frac{p^{\alpha-1} (1-p)^{\beta-1}}{B(\alpha, \beta)}}{\int_0^1 p^{\alpha-1} (1-p)^{\beta-1} dp} = \frac{p^{\alpha+\sum x_i - 1} (1-p)^{\beta+n-1-\sum x_i}}{B(\alpha', \beta')} = \text{Beta}(\alpha', \beta')$$

$$\theta \sim \mathcal{N}(\mu_0, \sigma_0^2)$$

$$x_1, \dots, x_n | \theta \stackrel{iid}{\sim} \mathcal{N}(\theta, \sigma^2)$$

$$\rightarrow \theta | x_1, \dots, x_n \sim \mathcal{N}\left(\frac{\mu_0/\sigma_0^2 + n/\sigma^2 \bar{x}_n}{1/\sigma_0^2 + n/\sigma^2}, \left(\frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\right)^{-1}\right)$$

$$\theta \sim \text{Inverse Gamma}(\alpha, \beta)$$

$$x_1, \dots, x_n | \theta \stackrel{iid}{\sim} \mathcal{N}(\mu, \theta)$$


$$\rightarrow \theta | x_1, \dots, x_n \sim \text{Inverse Gamma}\left(\alpha + \frac{n}{2}, \beta + \frac{\sum (x_i - \mu)^2}{n}\right)$$

Hidden Markov Model (HMM)

extra


Sampling

یک راه تقریبی برای سهول آوردن از توزیع (x) اش که ساپورت روی N آن bin تقسیم کنیم و احتمال رخ دادن هر bin را معادل سهولت زیر P_x در اون بازه در نظر بگیریم.



Inverse Transform Sampling

$$Z \sim \text{Unif}(0,1) \xrightarrow{\text{change of variable}} F_x^{-1}(z) \sim P_x(n)$$



این روش برای سهول نمودن کم بعده است و تصور آن به توزیع های چند بعدی سریع است منی باشد.
با این تعریف تد در ابعاد بالا دارون CDF قرم استانداری ندارد و طبقین correlation متغیرها در این روش capture نمی شوند.

برای بسیاری از توزیع ها (مانند گاوسی) فرم بسته ای برای تابع CDF و یا دارون آن وجود ندارد و بنابر این باید از روش های عددی برای توزیع آن ها استفاده شود. این کار به طور مخصوص در ابعاد بالا بسیار سخت و غیر جذب است.

برای سهول کرتن از توزیع G.T. با d بعد میمه d بار با روش از $\mathcal{N}(0,1)$ سهول گرفت و $\Sigma^{\frac{1}{2}} \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \sim \mathcal{N}(0, \Sigma)$ از inverse transform sampling همچنین میمه d بار به صورت sequential

همچنین میمه d بار به صورت دو ترتیب $x_{j+1}, \dots, x_1 \sim \mathcal{N}$ و سهول گرفت و دوچند دوچند در بردار پیدا.

Markov chain Monte Carlo (MCMC)

رونو های MCMC ساپورت درستگین دارند و دارند p در چندین میمه d دارند.

- محدودی ساپورت توزیع $\equiv \text{mc}$
- $p(\text{یال ها}) \equiv \pi_0 \equiv$ توزیع میده سه روی این ساپورت
- به دلیل خاصیت مارکو سهول گرتن مرحله مرحله از MC رو باید
- میمه یال ها (p) را طوری مسنجی کرد که:
- π^{ss} یعنی مسئله از π_0 داشته باشیم
- π^{ss} نسبت همان توزیع target شود

$$\text{support} = \{1, \dots, m\} \quad ① \dots ⑮$$

$$\text{support} = \{0, 1\}^d \quad \left[\begin{smallmatrix} 0 \\ 0 \end{smallmatrix} \right]_d \dots \left[\begin{smallmatrix} 1 \\ 1 \end{smallmatrix} \right]_d \rightarrow \text{sample } X_i$$

$$\left. \begin{aligned} \pi_{\text{target}} &= \pi_{\text{target}} T \\ \pi_{\text{target}}(a) T(a \rightarrow b) &= \pi_{\text{target}}(b) T(b \rightarrow a) \end{aligned} \right\} \text{detailed balance condition aka reversibility}$$

عدهان مجهو است که رون های متفاوت دليل آن تعریف می شود
رونو های MCMC به دو مسائلی می خورن که ساختار (ذات) ساده دارند توزیع اجراشی استفاده از این سادگی را می خواهند

$x_0 \dots x_{n-1}, x_n \dots x_{n+k} \dots x_{n+2k} \dots$ mixing time \rightarrow توزیع target سهول کردن غیره حاست
waiting time waiting time

Ising Model

$$P(x_1, \dots, x_d) = \frac{e^{-\sum_{i,j=1}^d (i \neq j) \theta_{ij} x_i x_j}}{\gamma(\theta)} \quad x_i \in \{\pm 1\}$$

$$\gamma(\theta) = \sum_{\text{all } x \in \{-1, 1\}^d} e^{-\frac{1}{2} \sum_{i,j} x_i x_j \theta_{ij}}, \quad \theta \equiv \sum \text{precision matrix}$$

partition Function

* در مجموع برای حالات ساده توزیع پیوسته باشد نیز جواب می داریم.

$$\pi^{ss} = \pi^{ss} P$$

$$\rightarrow \pi^{ss}(x) = \int \pi^{ss}(x') T P(x|x') dx'$$

* وقتی مکالمه توزیع دو بی محدودت تابع بسیاری را داریم . مثلاً partition function را بسیاری explicit نمایش نمی داریم.

Gibbs Sampling

منظر از x_i تمام بودار x بخوبی از این ایام آن است

$x = (x_1, \dots, x_d)$ choose i at random or sequentially, then

$$x'_{-i} = x_i \rightarrow x'_i \sim \pi(x_i | x_{-i})$$

target distribution

آنچه ایسینگ می خواهد $\pi(x)$

$$\pi(x_i | x_{-i}) = \frac{P(x_i, x_{-i})}{P(x_{-i})} = \underbrace{\frac{1}{\gamma(\theta)} e^{-\sum_{j \neq i} x_j x_j \theta_{ij}}}_{\text{one site}}$$

$$\begin{aligned} \text{if } \pi = P_{\text{ising}} \Rightarrow \pi(x_i | x_{-i}) &= \frac{P(x_i, x_{-i})}{P(x_{-i})} = \frac{P(x)}{P(x_{-i})} = \frac{\frac{1}{\gamma(\theta)} e^{-\sum_{j \neq i} x_j x_j \theta_{ij}}}{\frac{1}{\gamma(\theta)} e^{-\sum_{j \neq i} x_j x_j \theta_{ij}} + \frac{1}{\gamma(\theta)} e^{-\sum_{j \neq i} x_j x_j \theta_{ij}}} \\ &= \frac{e^{-\sum_j x_j x_j (\theta_{ij} + \theta_{ji})}}{e^{\sum_j x_j (\theta_{ij} + \theta_{ji})} + e^{-\sum_j x_j (\theta_{ij} + \theta_{ji})}} = \frac{e^{-\alpha x_i}}{e^\alpha + e^{-\alpha}} \rightarrow \text{one site partition function} \end{aligned}$$

Metropolis - Hastings

$$\pi(x) = A f(x) \rightarrow \text{target distribution}$$

نماید مالتی کلیت

$$q(x_{t+1} | x_t) \stackrel{\text{assumed}}{=} N(x_t, \sigma^2)$$

assume we have a good proposal function $q(x'|x_t)$

such that $q(x'|x_t)/q(x_t|x')$ can be easily computed. then

$$x' \sim q(\cdot | x_t) \rightarrow \begin{cases} \text{accept } x' \text{ with probability } \min(1, \frac{\pi(x') q(x_t|x')}{\pi(x_t) q(x'|x_t)}) \text{ and } x_{t+1} = x' \\ \text{reject } x' \text{ otherwise and } x_{t+1} = x_t \end{cases}$$

Hamiltonian Monte-Carlo (HMC)

$$\pi(x) \propto e^{U(x)}$$

$$p \sim N(0, \Sigma) \rightarrow \text{momentum}$$

$$K(p) = \frac{1}{2} p^T \Sigma^{-1} p \rightarrow \text{kinetic energy}$$

$$-\nabla_x U(x) = \text{score function}$$

$$U(x) + K(p) = H(x, p) = \text{const in time}$$

$$\rightarrow \frac{d}{dt} H(x, p) = \frac{dp^T}{dt} \nabla_p H + \frac{dx^T}{dt} \nabla_x H = 0$$

$$\begin{cases} \frac{dx}{dt} = \nabla_p H = \Sigma^{-1} p \\ \frac{dp}{dt} = -\nabla_x H = -\nabla U(x) \end{cases}$$

simulate from $0 \rightarrow T$

≈ HMC orbit ≈ langevin dynamics